

PPO、GRPO 与 DPO

从零开始的逐步公式推导

从概率、策略梯度和 KL 正则化出发，解释每一步“为什么成立”

本讲义按照严格的依赖顺序展开：先建立概率与强化学习基础，再推导 REINFORCE、基线、优势函数、重要性采样和信赖域；随后得到 PPO；在 PPO 的基础上推导 GRPO；最后从 Bradley-Terry 偏好模型与 KL 正则化强化学习目标出发，推导 DPO 的闭式形式。每一个新符号均在首次出现处解释。

阅读说明

这份讲义的目标不是只告诉你三个最终损失函数，而是回答以下问题：

- 策略梯度为什么会出现 $\nabla_{\theta} \log \pi_{\theta}(a | s)$ ？
- 为什么减去一个基线不会改变期望梯度，却能降低方差？
- 为什么 PPO 要使用“新旧策略概率之比”，以及 min 和 clip 究竟在限制什么？
- GRPO 为什么能够去掉价值模型？组内均值基线与严格无偏基线有什么差别？
- DPO 为什么不显式训练奖励模型，也不执行在线强化学习，却仍可从标准 RLHF 目标推导出来？
- PPO、GRPO 与 DPO 的“旧策略”与“参考策略”分别承担什么角色？

为了避免符号在不同论文之间冲突，本文采用统一记号。若同一概念在原论文中使用了不同字母，会在对应章节指出。

容易混淆的地方

“推导出来”不等于“拥有完全相同的理论保证”。例如，PPO 的裁剪目标受到 TRPO 思想启发，但裁剪本身并不提供 TRPO 的严格单调改进保证；GRPO 的组内标准化优势是实用估计器，并非通常意义下严格无偏的价值基线；DPO 与 KL 正则化 RLHF 目标的等价依赖于偏好模型、数据分布和函数表达能力等假设。本文会明确区分恒等变换、近似、启发式设计与统计假设。

目录

阅读说明	i
第一部分 共同的数学与强化学习基础	1
第一章 概率、期望、梯度与对数导数技巧	2
1.1 随机变量与概率分布	2
1.2 条件概率与联合概率	3
1.3 参数、目标函数与梯度	3
1.4 对数导数技巧：策略梯度的核心代数	3
1.5 为什么使用对数概率	4
1.6 Monte Carlo 估计	5
第二章 从马尔可夫决策过程到策略梯度	6
2.1 马尔可夫决策过程	6
2.2 轨迹、回报与目标	7
2.3 轨迹概率为什么只通过策略依赖参数	7
2.4 REINFORCE 的完整推导	8
2.5 为什么可以把整条轨迹回报替换成未来回报	8
2.6 Monte Carlo 梯度估计器	9
第三章 基线、价值函数、优势函数与 GAE	10
3.1 减去基线为什么不改变期望梯度	10
3.2 什么基线最能降低方差	11
3.3 状态价值、动作价值与优势函数	11
3.4 策略梯度定理的形式	12
3.5 Bellman 方程与时序差分误差	12
3.6 k 步优势估计	13

3.7	GAE 的推导	13
3.8	价值网络的训练目标	14
第四章	重要性采样、KL 散度与信赖域思想	15
4.1	为什么同一批数据不能无限重复用于普通策略梯度	15
4.2	重要性采样恒等式	15
4.3	从策略梯度到替代目标	16
4.4	KL 散度	16
4.5	性能差异引理	17
4.6	TRPO 的约束目标	18
第二部分	PPO：从策略梯度到裁剪替代目标	19
第五章	PPO 裁剪目标的逐步推导	20
5.1	PPO 要解决的具体矛盾	20
5.2	从未裁剪替代目标开始	20
5.3	裁剪函数	21
5.4	正优势情况下的分段推导	21
5.5	负优势情况下的分段推导	22
5.6	四种情况总表	22
5.7	裁剪曲线图	23
5.8	为什么说它是“悲观替代目标”	23
5.9	为什么在旧策略处保持相同一阶梯度	23
5.10	概率比与对数概率差	23
第六章	PPO 的完整训练目标与实现流程	25
6.1	策略项、价值项与熵项	25
6.2	价值函数裁剪	26
6.3	优势标准化	26
6.4	PPO 的完整算法	26
6.5	一个单样本数值例子	27
6.6	裁剪并不等于概率真的被限制在区间内	28
第七章	PPO 在大语言模型 RLHF 中的形式	29
7.1	语言模型如何对应 MDP	29
7.2	奖励模型与参考策略	29

7.3	KL 正则化奖励	30
7.4	LLM PPO 目标	31
7.5	为什么 LLM PPO 显存开销大	31
第三部分 GRPO：用组内相对奖励替代价值模型		32
第八章 从 PPO 到 GRPO		33
8.1	GRPO 改变了 PPO 的哪一部分	33
8.2	组采样	34
8.3	为什么相对奖励可以充当基线	34
8.4	严格无偏基线与 GRPO 组均值的区别	35
8.5	Outcome supervision 下的 token 优势	36
8.6	Process supervision 下的 token 优势	37
8.7	GRPO 的裁剪策略目标	37
8.8	GRPO 的 KL 正则项	37
第九章 GRPO 中 KL 估计器的推导		39
9.1	原始论文使用的正值估计器	39
9.2	为什么它逐样本非负	39
9.3	为什么其期望等于正向 KL	40
9.4	与常见对数比惩罚的关系	40
第十章 GRPO 的完整训练流程、数值例子与性质		41
10.1	完整流程	41
10.2	组内标准化数值例子	42
10.3	所有奖励相同时会发生什么	43
10.4	组大小 G 的作用	43
10.5	GRPO 的优势与代价	43
10.6	PPO 与 GRPO 的关系总结	44
第四部分 DPO：从 KL 正则化 RLHF 到二分类损失		45
第十一章 偏好数据、奖励模型与标准 RLHF 目标		46
11.1	偏好数据的形式	46
11.2	Bradley–Terry 偏好模型	46
11.3	显式奖励模型的训练	47

11.4 KL 正则化的 RLHF 目标	47
11.5 为什么 DPO 从这个目标出发	48
第十二章 KL 正则化目标的闭式最优策略	49
12.1 固定一个提示词进行优化	49
12.2 构造拉格朗日函数	49
12.3 验证这是最大值而不是最小值	50
12.4 从最优策略反解奖励	51
12.5 为什么仅依赖提示词 x 的常数不影响偏好	51
第十三章 DPO 损失函数的逐步推导	52
13.1 把隐式奖励代入偏好概率	52
13.2 最大似然得到 DPO 损失	52
13.3 为什么不能只最大化 winner 的概率	53
13.4 序列概率如何计算	53
13.5 DPO 梯度的完整推导	54
13.6 梯度权重的含义	54
13.7 beta 参数的双重解释	54
第十四章 DPO 的实现、数值例子与假设边界	56
14.1 概念伪代码	56
14.2 数值例子	57
14.3 DPO 与“训练一个隐式奖励模型”	57
14.4 DPO 等价成立依赖的关键假设	57
14.5 离线 DPO 的分布偏移问题	58
第五部分 三种算法的统一理解与对比	59
第十五章 PPO、GRPO 与 DPO 到底在优化什么	60
15.1 三个最终目标并列	60
15.2 三者最核心的共同点	60
15.3 online 与 offline 的差别	61
15.4 旧策略与参考策略的统一辨析	61
15.5 绝对奖励、相对奖励与偏好标签	61
15.5.1 PPO：绝对期望回报下的相对优势	61
15.5.2 GRPO：同题组内相对优势	62

15.5.3 DPO：成对回答的相对隐式奖励	62
15.6 稳定化机制的差别	62
第十六章 从梯度形式看三者的统一结构	63
16.1 PPO 的局部梯度	63
16.2 GRPO 的局部梯度	63
16.3 DPO 的局部梯度	63
16.4 统一模板	64
第十七章 应该如何选择以及常见误区	65
17.1 选择建议	65
17.2 误区一：PPO 的 clip 是硬约束	65
17.3 误区二：PPO 是从 TRPO 严格等价化简得到的	66
17.4 误区三：GRPO 的组均值是标准无偏 baseline	66
17.5 误区四：GRPO 完全不需要旧策略	66
17.6 误区五：DPO 只是 winner SFT	66
17.7 误区六：DPO 的 beta 越大，模型一定离参考越远	66
17.8 误区七：参考策略和旧策略可以随意互换	66
17.9 误区八：优势为正就表示原始奖励为正	66
附录 A 完整符号表	67
附录 B 关键公式的最短推导链	69
B.1 从期望回报到 REINFORCE	69
B.2 从 REINFORCE 到优势策略梯度	69
B.3 从旧策略数据到 PPO	69
B.4 从 PPO 到 GRPO	70
B.5 从 KL 正则化 RLHF 到 DPO	70
附录 C 自测题与答案	71
结语	73
参考文献	74

第一部分

共同的数学与强化学习基础

概率、期望、梯度与对数导数技巧

1.1 随机变量与概率分布

本节新符号

X	随机变量。它不是固定数，而是从某个概率分布中抽取的结果。
x	随机变量 X 的一个具体取值。
$p(x)$	离散随机变量取值为 x 的概率，满足 $p(x) \geq 0$ 且 $\sum_x p(x) = 1$ 。
$\mathbb{E}_{X \sim p}[f(X)]$	当 X 按分布 p 采样时，函数 $f(X)$ 的期望。

对离散随机变量，期望的定义是

$$\mathbb{E}_{X \sim p}[f(X)] = \sum_x p(x)f(x). \quad (1.1)$$

它是“用概率作为权重的加权平均”。例如，若动作 a 有三个可能取值，概率分别为 0.2, 0.5, 0.3，对应收益分别为 1, 4, -2，则期望收益为

$$0.2 \times 1 + 0.5 \times 4 + 0.3 \times (-2) = 1.6.$$

期望最重要的性质是线性性：

$$\mathbb{E}[c_1 X + c_2 Y] = c_1 \mathbb{E}[X] + c_2 \mathbb{E}[Y], \quad (1.2)$$

其中 c_1, c_2 是常数。即使 X 与 Y 不独立，这条性质仍成立。

1.2 条件概率与联合概率

本节新符号

$p(x, y)$ $X = x$ 与 $Y = y$ 同时发生的联合概率。

$p(y | x)$ 已知 $X = x$ 时, $Y = y$ 的条件概率。

联合概率可以按链式法则分解：

$$p(x, y) = p(x)p(y | x). \quad (1.3)$$

对序列 $x_1, x_2, \dots, x_T$, 链式法则推广为

$$p(x_1, \dots, x_T) = p(x_1) \prod_{t=2}^T p(x_t | x_1, \dots, x_{t-1}). \quad (1.4)$$

大语言模型的自回归概率正是这一公式：一句完整回答的概率等于每个 token 条件概率的乘积。

1.3 参数、目标函数与梯度

本节新符号

$\theta \in \mathbb{R}^d$ 模型参数向量, 共有 d 个可训练参数。

$J(\theta)$ 希望最大化的标量目标函数, 例如期望累计奖励。

$\nabla_{\theta} J(\theta)$ J 对参数向量 θ 的梯度, 即由所有偏导数组成的向量。

$\alpha > 0$ 学习率, 控制每次更新的步长。

若要最大化 J , 最基本的梯度上升更新为

$$\theta \leftarrow \theta + \alpha \nabla_{\theta} J(\theta). \quad (1.5)$$

梯度给出局部一阶近似下增长最快的方向。若优化器采用“最小化损失”的接口, 则定义 $\mathcal{L}(\theta) = -J(\theta)$, 执行梯度下降即可。

1.4 对数导数技巧：策略梯度的核心代数

设 $p_{\theta}(x)$ 是由参数 θ 控制的概率分布。因为

$$\nabla_{\theta} \log p_{\theta}(x) = \frac{1}{p_{\theta}(x)} \nabla_{\theta} p_{\theta}(x), \quad (1.6)$$

两边乘以 $p_\theta(x)$ 得到

$$\boxed{\nabla_\theta p_\theta(x) = p_\theta(x) \nabla_\theta \log p_\theta(x).} \quad (1.7)$$

这称为**对数导数技巧**、**score function trick** 或 **likelihood-ratio trick**。

现在考虑

$$J(\theta) = \mathbb{E}_{X \sim p_\theta}[f(X)] = \sum_x p_\theta(x) f(x), \quad (1.8)$$

其中 $f(x)$ 暂时不显式依赖 θ 。对 θ 求梯度：

$$\nabla_\theta J(\theta) = \nabla_\theta \sum_x p_\theta(x) f(x) \quad (1.9)$$

$$= \sum_x \nabla_\theta p_\theta(x) f(x) \quad (1.10)$$

$$= \sum_x p_\theta(x) \nabla_\theta \log p_\theta(x) f(x) \quad (1.11)$$

$$= \boxed{\mathbb{E}_{X \sim p_\theta}[f(X) \nabla_\theta \log p_\theta(X)]}. \quad (1.12)$$

为什么可以这样做

我们无法直接对一次离散采样结果求导：例如采样到 token “北京” 还是 “上海” 是离散事件。但可以对“采到这个结果的对数概率”求导。对数导数技巧把“概率分布的期望梯度”改写为可通过采样估计的期望，因此成为 REINFORCE、PPO 和 GRPO 的共同起点。

1.5 为什么使用对数概率

概率乘积的对数会变为求和。若

$$p_\theta(x_{1:T}) = \prod_{t=1}^T p_\theta(x_t | x_{<t}),$$

其中 $x_{1:T}$ 表示从 x_1 到 x_T 的完整序列， $x_{<t}$ 表示 $x_1, \dots, x_{t-1}$ ，则

$$\log p_\theta(x_{1:T}) = \sum_{t=1}^T \log p_\theta(x_t | x_{<t}), \quad (1.13)$$

$$\nabla_\theta \log p_\theta(x_{1:T}) = \sum_{t=1}^T \nabla_\theta \log p_\theta(x_t | x_{<t}). \quad (1.14)$$

因此，一个序列级奖励可以通过上述和式向每一个 token 的决策传播梯度。

1.6 Monte Carlo 估计

实际中无法枚举所有 x ，因此从 p_θ 独立采样 N 个样本 $x^{(1)}, \dots, x^{(N)}$ ，用样本均值近似期望：

$$\mathbb{E}_{X \sim p_\theta}[h(X)] \approx \frac{1}{N} \sum_{i=1}^N h(x^{(i)}). \quad (1.15)$$

代入对数导数结果：

$$\nabla_\theta J(\theta) \approx \frac{1}{N} \sum_{i=1}^N f(x^{(i)}) \nabla_\theta \log p_\theta(x^{(i)}). \quad (1.16)$$

该估计在满足常见正则条件时是无偏的，但方差可能很大。后面引入的价值函数、优势函数、组内基线，本质上都在处理方差与信用分配问题。

从马尔可夫决策过程到策略梯度

2.1 马尔可夫决策过程

一个折扣马尔可夫决策过程（Markov Decision Process, MDP）可写成

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma). \quad (2.1)$$

本节新符号

$\mathcal{S}$	状态空间，包含所有可能状态。
$s_t \in \mathcal{S}$	第 t 个时间步的状态。
$\mathcal{A}$	动作空间，包含所有可能动作。
$a_t \in \mathcal{A}$	第 t 个时间步采取的动作。
$P(s_{t+1} s_t, a_t)$	环境转移概率：在 s_t 执行动作 a_t 后到达 s_{t+1} 的概率。
r_t	第 t 步后获得的即时奖励；也可写为 $r(s_t, a_t, s_{t+1})$ 。
$\rho_0(s_0)$	初始状态 s_0 的概率分布。
$\gamma \in [0, 1]$	折扣因子。越接近 1，越重视长远奖励。
$\pi_\theta(a s)$	参数为 θ 的随机策略：在状态 s 选择动作 a 的概率。

“马尔可夫”表示：给定当前状态和动作后，下一状态的分布不再依赖更早历史，即

$$P(s_{t+1} | s_0, a_0, \dots, s_t, a_t) = P(s_{t+1} | s_t, a_t).$$

在大语言模型中，可以把提示词与已经生成的 token 前缀视为状态，把下一个 token 视为动作：

$$s_t = (x, y_{<t}), \quad a_t = y_t, \quad (2.2)$$

其中 x 是提示词, $y_{<t}$ 是已生成前缀, y_t 是当前生成 token。

2.2 轨迹、回报与目标

本节新符号

τ	一条完整轨迹, $\tau = (s_0, a_0, r_0, s_1, a_1, r_1, \dots)$ 。
$R(\tau)$	整条轨迹的折扣累计奖励。
G_t	从时间步 t 开始的 reward-to-go, 即未来回报。
$J(\theta)$	策略 π_θ 的期望回报, 是要最大化的目标。

有限时域长度为 T 时, 整条轨迹回报可定义为

$$R(\tau) = \sum_{t=0}^{T-1} \gamma^t r_t. \quad (2.3)$$

从时刻 t 开始的回报为

$$G_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots. \quad (2.4)$$

目标函数是

$$J(\theta) = \mathbb{E}_{\tau \sim p_\theta(\tau)}[R(\tau)]. \quad (2.5)$$

2.3 轨迹概率为什么只通过策略依赖参数

按照概率链式法则, 一条轨迹的概率为

$$p_\theta(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t | s_t) P(s_{t+1} | s_t, a_t). \quad (2.6)$$

若环境动力学 P 与初始分布 ρ_0 不由策略参数 θ 控制, 则

$$\log p_\theta(\tau) = \log \rho_0(s_0) + \sum_{t=0}^{T-1} \log \pi_\theta(a_t | s_t) + \sum_{t=0}^{T-1} \log P(s_{t+1} | s_t, a_t), \quad (2.7)$$

$$\nabla_\theta \log p_\theta(\tau) = \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t | s_t). \quad (2.8)$$

环境项的梯度为零。这一点非常重要: 策略梯度不要求知道环境转移概率的解析形式, 只需能够与环境交互采样。

2.4 REINFORCE 的完整推导

从

$$J(\theta) = \sum_{\tau} p_{\theta}(\tau) R(\tau)$$

出发：

$$\nabla_{\theta} J(\theta) = \sum_{\tau} \nabla_{\theta} p_{\theta}(\tau) R(\tau) \quad (2.9)$$

$$= \sum_{\tau} p_{\theta}(\tau) \nabla_{\theta} \log p_{\theta}(\tau) R(\tau) \quad (2.10)$$

$$= \mathbb{E}_{\tau \sim p_{\theta}} [R(\tau) \nabla_{\theta} \log p_{\theta}(\tau)] \quad (2.11)$$

$$= \mathbb{E}_{\tau \sim p_{\theta}} \left[R(\tau) \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]. \quad (2.12)$$

交换求和顺序：

$$\nabla_{\theta} J(\theta) = \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R(\tau) \right]. \quad (2.13)$$

这已经是最基本的 REINFORCE 梯度。

2.5 为什么可以把整条轨迹回报替换成未来回报

在时刻 t 选择的动作 a_t 不可能影响已经发生的奖励 $r_0, \dots, r_{t-1}$ 。形式化地，把

$$R(\tau) = \underbrace{\sum_{k=0}^{t-1} \gamma^k r_k}_{\text{过去奖励}} + \underbrace{\sum_{k=t}^{T-1} \gamma^k r_k}_{\text{当前及未来奖励}}$$

代入。对任意只依赖 s_t 以前历史的随机变量 B_t ，有

$$\mathbb{E}_{a_t \sim \pi_{\theta}(\cdot | s_t)} [B_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)] \quad (2.14)$$

$$= B_t \sum_{a_t} \pi_{\theta}(a_t | s_t) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \quad (2.15)$$

$$= B_t \sum_{a_t} \nabla_{\theta} \pi_{\theta}(a_t | s_t) \quad (2.16)$$

$$= B_t \nabla_{\theta} \sum_{a_t} \pi_{\theta}(a_t | s_t) \quad (2.17)$$

$$= B_t \nabla_{\theta} 1 = 0. \quad (2.18)$$

因此过去奖励与当前 score function 的乘积期望为零，可以删除，得到

$$\nabla_{\theta} J(\theta) = \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) G_t \right]. \quad (2.19)$$

直觉解释

若某一步之后获得了高回报，就提高当时所选动作的概率；若回报低，就降低该动作的概率。 $\nabla \log \pi$ 指出“怎样调整参数才能提高该动作概率”， G_t 决定调整方向和幅度。

2.6 Monte Carlo 梯度估计器

采样 N 条轨迹，记第 i 条轨迹在时刻 t 的状态、动作和回报为 $s_t^{(i)}, a_t^{(i)}, G_t^{(i)}$ ，则

$$\hat{g}_{\text{REINFORCE}} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T_i-1} G_t^{(i)} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} | s_t^{(i)}). \quad (2.20)$$

其中 T_i 是第 i 条轨迹长度， $\hat{g}$ 上方的帽子表示“由有限样本得到的估计”。

容易混淆的地方

REINFORCE 的问题通常不是期望方向错误，而是方差很大。同一个动作之后的回报会受到大量随机因素影响，因此单条轨迹可能给出噪声很强的梯度。PPO 的优势估计、GRPO 的组内比较，都建立在降低方差与稳定更新的需求之上。

基线、价值函数、优势函数与 GAE

3.1 减去基线为什么不改变期望梯度

考虑在策略梯度中将 G_t 替换为 $G_t - b(s_t)$:

$$\mathbb{E}[\nabla_{\theta} \log \pi_{\theta}(a_t | s_t)(G_t - b(s_t))] . \quad (3.1)$$

本节新符号

$b(s_t)$ 基线函数，只依赖当前状态 s_t ，不依赖当前动作 a_t 。

基线项的期望为

$$\mathbb{E}_{s_t} \mathbb{E}_{a_t \sim \pi_{\theta}(\cdot | s_t)} [b(s_t) \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)] \quad (3.2)$$

$$= \mathbb{E}_{s_t} \left[b(s_t) \sum_a \pi_{\theta}(a | s_t) \nabla_{\theta} \log \pi_{\theta}(a | s_t) \right] \quad (3.3)$$

$$= \mathbb{E}_{s_t} \left[b(s_t) \sum_a \nabla_{\theta} \pi_{\theta}(a | s_t) \right] \quad (3.4)$$

$$= \mathbb{E}_{s_t} [b(s_t) \nabla_{\theta} 1] = 0. \quad (3.5)$$

因此

$$\mathbb{E}[\nabla \log \pi G_t] = \mathbb{E}[\nabla \log \pi (G_t - b(s_t))] . \quad (3.6)$$

为什么可以这样做

只要基线在给定状态后不随“当前采到哪个动作”而变化，它就不会系统性偏向任何动作。它只改变每个样本的权重，从而可以降低方差，而不会改变期望梯度。

3.2 什么基线最能降低方差

令

$$z_t = \nabla_{\theta} \log \pi_{\theta}(a_t | s_t).$$

在固定状态 s 下，希望选择标量 b ，使估计器 $z(G - b)$ 的二阶矩最小：

$$\min_b \mathbb{E} [\|z\|_2^2 (G - b)^2 | s]. \quad (3.7)$$

对 b 求导并令其为零：

$$0 = \frac{\partial}{\partial b} \mathbb{E} [\|z\|_2^2 (G - b)^2 | s] \quad (3.8)$$

$$= -2 \mathbb{E} [\|z\|_2^2 (G - b) | s]. \quad (3.9)$$

所以最优标量基线为

$$b^*(s) = \frac{\mathbb{E}[\|z\|_2^2 G | s]}{\mathbb{E}[\|z\|_2^2 | s]}. \quad (3.10)$$

实践中通常用状态价值函数 $V^{\pi}(s)$ 近似它，因为更容易学习，也能显著降低方差。

3.3 状态价值、动作价值与优势函数

本节新符号

$V^{\pi}(s)$	状态价值函数：从状态 s 开始并继续执行策略 π 时的期望未来回报。
$Q^{\pi}(s, a)$	动作价值函数：在状态 s 先执行动作 a ，之后继续执行策略 π 时的期望未来回报。
$A^{\pi}(s, a)$	优势函数，衡量动作 a 相对该状态下平均行为好多少。

定义分别为

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t | s_t = s], \quad (3.11)$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t | s_t = s, a_t = a], \quad (3.12)$$

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s). \quad (3.13)$$

由全期望公式，

$$V^{\pi}(s) = \sum_a \pi(a | s) Q^{\pi}(s, a), \quad (3.14)$$

$$\sum_a \pi(a | s) A^{\pi}(s, a) = \sum_a \pi(a | s) Q^{\pi}(s, a) - V^{\pi}(s) = 0. \quad (3.15)$$

因此优势函数在当前策略下的动作均值为零。

直觉解释

$Q^\pi(s, a)$ 说的是“做这个动作后预计能拿多少分”； $V^\pi(s)$ 说的是“在这个状态下按当前平均水平预计能拿多少分”；两者相减后， $A^\pi(s, a)$ 只保留“这个动作比平均水平好或坏多少”。

3.4 策略梯度定理的形式

定义折扣状态访问分布

$$d_\gamma^\pi(s) = (1 - \gamma) \sum_{t=0}^{\infty} \gamma^t \mathbb{P}(s_t = s \mid \pi). \quad (3.16)$$

本节新符号

$d_\gamma^\pi(s)$ 策略 π 下对状态 s 的折扣访问概率；乘上 $(1 - \gamma)$ 后总和为 1。

策略梯度定理可写为

$$\nabla_\theta J(\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{\substack{s \sim d_\gamma^{\pi_\theta} \\ a \sim \pi_\theta(\cdot|s)}} [\nabla_\theta \log \pi_\theta(a \mid s) Q^{\pi_\theta}(s, a)]. \quad (3.17)$$

利用基线不改变期望的结论，可替换为优势函数：

$$\nabla_\theta J(\theta) = \frac{1}{1 - \gamma} \mathbb{E}_{s,a} [\nabla_\theta \log \pi_\theta(a \mid s) A^{\pi_\theta}(s, a)]. \quad (3.18)$$

这就是 PPO 论文中常见梯度估计器

$$\hat{g} = \hat{\mathbb{E}}_t [\nabla_\theta \log \pi_\theta(a_t \mid s_t) \hat{A}_t]$$

的理论来源。 $\hat{\mathbb{E}}_t$ 表示对批次中时间步做经验平均， $\hat{A}_t$ 是优势函数的样本估计。

3.5 Bellman 方程与时序差分误差

价值函数满足 Bellman 期望方程：

$$V^\pi(s_t) = \mathbb{E}_\pi[r_t + \gamma V^\pi(s_{t+1}) \mid s_t]. \quad (3.19)$$

若用参数为 ψ 的价值网络 $V_\psi(s)$ 近似真实价值，定义一步时序差分误差

$$\delta_t = r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t). \quad (3.20)$$

本节新符号

ψ	价值网络参数，通常与策略参数 θ 分开。
$V_\psi(s)$	对 $V^\pi(s)$ 的函数近似。
δ_t	一步 TD error；实际获得的“一步奖励加下一状态价值”与当前预测价值之差。

若 $V_\psi = V^\pi$ ，则给定 (s_t, a_t) 时， δ_t 的条件期望为

$$\mathbb{E}[\delta_t | s_t, a_t] = \mathbb{E}[r_t + \gamma V^\pi(s_{t+1}) | s_t, a_t] - V^\pi(s_t) \quad (3.21)$$

$$= Q^\pi(s_t, a_t) - V^\pi(s_t) \quad (3.22)$$

$$= A^\pi(s_t, a_t). \quad (3.23)$$

因此 TD error 是优势函数的一步估计。

3.6 k 步优势估计

把若干个 TD error 依次展开。两步估计为

$$\delta_t + \gamma \delta_{t+1} = r_t + \gamma V(s_{t+1}) - V(s_t) \quad (3.24)$$

$$+ \gamma[r_{t+1} + \gamma V(s_{t+2}) - V(s_{t+1})] \quad (3.25)$$

$$= r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t). \quad (3.26)$$

中间的 $+\gamma V(s_{t+1})$ 与 $-\gamma V(s_{t+1})$ 抵消。一般地， k 步优势估计为

$$\hat{A}_t^{(k)} = \sum_{l=0}^{k-1} \gamma^l r_{t+l} + \gamma^k V_\psi(s_{t+k}) - V_\psi(s_t) = \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}. \quad (3.27)$$

k 小时更多依赖价值网络，方差较低但价值偏差影响较大； k 大时更接近 Monte Carlo 回报，偏差较小但方差更高。

3.7 GAE 的推导

广义优势估计（Generalized Advantage Estimation, GAE）用参数 $\lambda \in [0, 1]$ 对同步数的优势估计做指数加权：

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = (1 - \lambda) \sum_{k=0}^{\infty} \lambda^k \hat{A}_t^{(k)}. \quad (3.28)$$

将 $\hat{A}_t^{(k)} = \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}$ 代入：

$$\hat{A}_t^{\text{GAE}} = (1 - \lambda) \sum_{k=1}^{\infty} \lambda^{k-1} \sum_{l=0}^{k-1} \gamma^l \delta_{t+l}. \quad (3.29)$$

固定某个 δ_{t+l} ，它出现在所有 $k \geq l+1$ 的项中，系数为

$$(1 - \lambda) \gamma^l \sum_{k=l+1}^{\infty} \lambda^{k-1} = (1 - \lambda) \gamma^l \lambda^l \sum_{j=0}^{\infty} \lambda^j \quad (3.30)$$

$$= (1 - \lambda) \gamma^l \lambda^l \frac{1}{1 - \lambda} \quad (3.31)$$

$$= (\gamma \lambda)^l. \quad (3.32)$$

所以

$$\boxed{\hat{A}_t^{\text{GAE}} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}.} \quad (3.33)$$

有限轨迹中截断为

$$\hat{A}_t = \delta_t + \gamma \lambda \delta_{t+1} + (\gamma \lambda)^2 \delta_{t+2} + \dots. \quad (3.34)$$

递推实现为

$$\boxed{\hat{A}_t = \delta_t + \gamma \lambda (1 - d_t) \hat{A}_{t+1},} \quad (3.35)$$

其中 $d_t \in \{0, 1\}$ 表示第 t 步后是否真正终止；真正终止后不再 bootstrap。

推导结论

- $\lambda = 0$: $\hat{A}_t = \delta_t$ ，方差低、更加依赖价值网络。
- $\lambda \rightarrow 1$: 接近完整 Monte Carlo 回报减价值基线，偏差通常较小、方差较高。
- PPO 中常用 GAE，是为了在价值估计偏差与采样方差之间折中。

3.8 价值网络的训练目标

定义目标回报

$$\hat{V}_t^{\text{target}} = \hat{A}_t + V_{\psi_{\text{old}}}(s_t), \quad (3.36)$$

其中 ψ_{old} 表示采样时的旧价值网络参数。常见价值损失为

$$\mathcal{L}_V(\psi) = \hat{\mathbb{E}}_t \left[\left(V_{\psi}(s_t) - \hat{V}_t^{\text{target}} \right)^2 \right]. \quad (3.37)$$

价值网络通过回归未来回报，为策略梯度提供低方差基线。PPO 是典型 actor-critic 方法：策略网络是 actor，价值网络是 critic。

重要性采样、KL 散度与信赖域思想

4.1 为什么同一批数据不能无限重复用于普通策略梯度

假设数据由旧策略 $\pi_{\theta_{\text{old}}}$ 采样。第一次更新后，当前策略变成 π_{θ} 。普通策略梯度理论要求样本来自当前策略，但现有动作实际来自旧策略。如果直接重复最大化

$$\hat{\mathbb{E}}_t[\log \pi_{\theta}(a_t | s_t) \hat{A}_t],$$

就会出现分布不匹配，而且同一批高优势动作的概率可能被过度推高，导致策略发生破坏性更新。

4.2 重要性采样恒等式

设希望计算目标分布 p 下的期望，但样本来自行为分布 q 。若对所有 $p(x) > 0$ 的位置都有 $q(x) > 0$ ，则

$$\mathbb{E}_{x \sim p}[f(x)] = \sum_x p(x) f(x) \quad (4.1)$$

$$= \sum_x q(x) \frac{p(x)}{q(x)} f(x) \quad (4.2)$$

$$= \mathbb{E}_{x \sim q} \left[\frac{p(x)}{q(x)} f(x) \right]. \quad (4.3)$$

本节新符号

$$w(x) = p(x)/q(x)$$

重要性权重，用于把在 q 下采到的样本重新加权为 p 下的期望。

在策略优化中，对固定状态 s_t ，定义概率比

$$r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}. \quad (4.4)$$

若 $r_t = 1.3$ ，表示当前策略给已采动作的概率是旧策略的 1.3 倍；若 $r_t = 0.7$ ，表示降为 0.7 倍。

4.3 从策略梯度到替代目标

以旧策略采样的状态和动作构造

$$L^{\text{CPI}}(\theta) = \hat{\mathbb{E}}_t \left[r_t(\theta) \hat{A}_t \right]. \quad (4.5)$$

这里 CPI 表示 Conservative Policy Iteration。由于 $\hat{A}_t$ 在优化期间被视为固定常数，且在 $\theta = \theta_{\text{old}}$ 时 $r_t = 1$ ，有

$$\nabla_{\theta} L^{\text{CPI}}(\theta) \big|_{\theta=\theta_{\text{old}}} = \hat{\mathbb{E}}_t \left[\nabla_{\theta} r_t(\theta) \big|_{\theta_{\text{old}}} \hat{A}_t \right] \quad (4.6)$$

$$= \hat{\mathbb{E}}_t \left[\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}_t \right]_{\theta=\theta_{\text{old}}}. \quad (4.7)$$

因为

$$\nabla_{\theta} r_t = r_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t),$$

而旧参数处 $r_t = 1$ 。因此替代目标在起点处与策略梯度具有相同的一阶方向。

容易混淆的地方

重要性比只修正了“给定状态下的动作分布”。更新策略后，状态访问分布也会改变。 L^{CPI} 仍使用旧策略采到的状态，因此它是局部替代目标，而不是新策略真实回报的精确表达。限制策略变化幅度，就是为了让状态分布变化也保持较小。

4.4 KL 散度

两个离散分布 p 与 q 的 KL 散度定义为

$$D_{\text{KL}}(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)} = \mathbb{E}_{x \sim p} \left[\log \frac{p(x)}{q(x)} \right]. \quad (4.8)$$

本节新符号

$D_{\text{KL}}(p||q)$ 从 q 近似 p 时的信息差异。它非负，且只有 $p = q$ 时为零；通常不对称。

KL 非负可由 Jensen 不等式证明：

$$-D_{\text{KL}}(p\|q) = \mathbb{E}_{x \sim p} \left[\log \frac{q(x)}{p(x)} \right] \quad (4.9)$$

$$\leq \log \mathbb{E}_{x \sim p} \left[\frac{q(x)}{p(x)} \right] \quad (4.10)$$

$$= \log \sum_x q(x) = 0. \quad (4.11)$$

故 $D_{\text{KL}}(p\|q) \geq 0$ 。

4.5 性能差异引理

对两个策略 π 与 π' ，性能差异引理给出

$$J(\pi') - J(\pi) = \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d_{\gamma}^{\pi'} \\ a \sim \pi'(\cdot|s)}} [A^{\pi}(s, a)]. \quad (4.12)$$

它可以由 TD 望远镜求和得到。令

$$\delta_t^{\pi} = r_t + \gamma V^{\pi}(s_{t+1}) - V^{\pi}(s_t),$$

在策略 π' 下求期望，并对时间折扣求和：

$$\mathbb{E}_{\pi'} \sum_{t=0}^{\infty} \gamma^t \delta_t^{\pi} = \mathbb{E}_{\pi'} \sum_{t=0}^{\infty} \gamma^t r_t - \mathbb{E}[V^{\pi}(s_0)] \quad (4.13)$$

$$= J(\pi') - J(\pi). \quad (4.14)$$

另一方面，给定 s_t, a_t ， δ_t^{π} 的期望是 $A^{\pi}(s_t, a_t)$ ，从而得到上式。

性能差异引理中状态分布是新策略的 $d^{\pi'}$ ，难以直接用旧数据计算。TRPO 定义替代目标

$$L_{\pi}(\pi') = J(\pi) + \frac{1}{1-\gamma} \mathbb{E}_{\substack{s \sim d_{\gamma}^{\pi} \\ a \sim \pi'(\cdot|s)}} [A^{\pi}(s, a)], \quad (4.15)$$

即只把状态分布替换为旧策略的 d^{π} 。当新旧策略足够接近时，二者状态分布也接近，替代目标更可信。

4.6 TRPO 的约束目标

TRPO 近似求解

$$\max_{\theta} \quad \hat{\mathbb{E}}_t \left[\frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} \hat{A}_t \right], \quad (4.16)$$

$$\text{s.t.} \quad \hat{\mathbb{E}}_t \left[D_{\text{KL}}(\pi_{\theta_{\text{old}}}(\cdot | s_t) \parallel \pi_{\theta}(\cdot | s_t)) \right] \leq \delta. \quad (4.17)$$

本节新符号

$\delta > 0$ 信赖域半径，限制平均 KL 散度不超过给定阈值。

“信赖域”表示：只在旧参数附近、局部近似可信的区域内更新。TRPO 使用目标的一阶近似和 KL 约束的二阶近似，并借助共轭梯度求解，理论动机强，但实现复杂。

直觉解释

替代目标像一张只在当前位置附近准确的地图。若一步走得太远，地图误差会变大。TRPO 明确画出一个允许移动的区域；PPO 则试图通过更简单的裁剪，让优化器在收益已经“足够好”后失去继续远离旧策略的动力。

第二部分

PPO：从策略梯度到裁剪替代目标

PPO 裁剪目标的逐步推导

5.1 PPO 要解决的具体矛盾

在 on-policy 策略梯度中，通常执行以下循环：

1. 用当前策略与环境交互，收集一批轨迹；
2. 根据这批轨迹估计优势；
3. 更新策略；
4. 丢弃旧数据，重新采样。

若每批数据只做一次很小的梯度更新，训练较稳定，但样本利用率低。若在同一批数据上做很多轮更新，策略会逐渐远离生成这批数据的旧策略，重要性比可能变得极端，局部替代目标不再可靠。PPO 的目标是：允许对同一批数据执行多轮小批量更新，同时阻止单个样本持续推动策略发生过大改变。

5.2 从未裁剪替代目标开始

定义

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}. \quad (5.1)$$

未裁剪目标为

$$L^{\text{CPI}}(\theta) = \hat{\mathbb{E}}_t[r_t(\theta)\hat{A}_t]. \quad (5.2)$$

对一个固定样本，只看

$$\ell_t^{\text{CPI}}(r) = r\hat{A}_t. \quad (5.3)$$

若 $\hat{A}_t > 0$ ，增大 r 会一直提高目标；若 $\hat{A}_t < 0$ ，减小 r 会一直提高目标。没有约束时，优化器存在把概率比推得过远的激励。

5.3 裁剪函数

定义

$$\text{clip}(r, 1 - \epsilon, 1 + \epsilon) = \begin{cases} 1 - \epsilon, & r < 1 - \epsilon, \\ r, & 1 - \epsilon \leq r \leq 1 + \epsilon, \\ 1 + \epsilon, & r > 1 + \epsilon, \end{cases} \quad (5.4)$$

其中 $\epsilon \in (0, 1)$ 是裁剪范围超参数，PPO 原论文给出的典型示例为 $\epsilon = 0.2$ [5]。

单独使用裁剪项会得到

$$\text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t. \quad (5.5)$$

但只用这个表达式存在问题：当概率变化让目标变差时，也可能被裁剪，从而掩盖坏更新。因此 PPO 取未裁剪项与裁剪项的较小值：

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]. \quad (5.6)$$

5.4 正优势情况下的分段推导

假设 $\hat{A}_t > 0$ 。因为乘以正数不改变大小关系：

$$\ell_t^{\text{CLIP}}(r) = \min(r \hat{A}_t, \text{clip}(r, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \quad (5.7)$$

$$= \hat{A}_t \min(r, \text{clip}(r, 1 - \epsilon, 1 + \epsilon)). \quad (5.8)$$

逐区间讨论：

- $r < 1 - \epsilon$ 时， $r < \text{clip}(r) = 1 - \epsilon$ ，取较小的 r ；
- $1 - \epsilon \leq r \leq 1 + \epsilon$ 时，两项相同；
- $r > 1 + \epsilon$ 时， $\text{clip}(r) = 1 + \epsilon < r$ ，取 $1 + \epsilon$ 。

所以

$$\ell_t^{\text{CLIP}}(r) = \hat{A}_t \min(r, 1 + \epsilon), \quad \hat{A}_t > 0. \quad (5.9)$$

等价分段形式为

$$\ell_t^{\text{CLIP}}(r) = \begin{cases} r \hat{A}_t, & r \leq 1 + \epsilon, \\ (1 + \epsilon) \hat{A}_t, & r > 1 + \epsilon. \end{cases} \quad (5.10)$$

直觉解释

正优势表示该动作比平均水平好，应提高其概率。但当新策略已经把该动作概率提高到旧策略的 $1 + \epsilon$ 倍以上后，这个样本不再因为“继续提高概率”而贡献更大目标值。注意：若概率错误地降低，PPO 不会在下侧裁掉惩罚，仍会推动它回升。

5.5 负优势情况下的分段推导

假设 $\hat{A}_t < 0$ 。乘以负数会反转大小关系：

$$\ell_t^{\text{CLIP}}(r) = \min(r\hat{A}_t, \text{clip}(r, 1 - \epsilon, 1 + \epsilon)\hat{A}_t) \quad (5.11)$$

$$= \hat{A}_t \max(r, \text{clip}(r, 1 - \epsilon, 1 + \epsilon)). \quad (5.12)$$

逐区间讨论：

- $r < 1 - \epsilon$ 时， $\text{clip}(r) = 1 - \epsilon > r$ ，由于优势为负，裁剪项更小，取裁剪项；
- $1 - \epsilon \leq r \leq 1 + \epsilon$ 时，两项相同；
- $r > 1 + \epsilon$ 时， $r > \text{clip}(r)$ ，乘负优势后未裁剪项更小，取未裁剪项。

所以

$$\ell_t^{\text{CLIP}}(r) = \hat{A}_t \max(r, 1 - \epsilon), \quad \hat{A}_t < 0. \quad (5.13)$$

等价分段形式为

$$\ell_t^{\text{CLIP}}(r) = \begin{cases} (1 - \epsilon)\hat{A}_t, & r < 1 - \epsilon, \\ r\hat{A}_t, & r \geq 1 - \epsilon. \end{cases} \quad (5.14)$$

直觉解释

负优势表示该动作比平均水平差，应降低其概率。但当概率已经降到旧策略的 $1 - \epsilon$ 倍以下后，这个样本不再奖励继续降低。若概率反而升高，损失不会被上侧裁掉，坏更新仍会受到惩罚。

5.6 四种情况总表

表 5.1: PPO 裁剪对单样本更新激励的影响

优势符号	概率比区域	含义	裁剪行为
$\hat{A}_t > 0$	$r_t > 1 + \epsilon$	好动作概率已经提高太多	截断继续提高的收益
$\hat{A}_t > 0$	$r_t < 1 - \epsilon$	好动作概率反而降低很多	不截断，继续惩罚
$\hat{A}_t < 0$	$r_t < 1 - \epsilon$	坏动作概率已经降低太多	截断继续降低的收益
$\hat{A}_t < 0$	$r_t > 1 + \epsilon$	坏动作概率反而提高很多	不截断，继续惩罚

这解释了为什么必须同时使用 $\min$ 与 clip ：PPO 只在变化将使替代目标“进一步变好”且已经越过阈值时移除激励，不会掩盖让目标变差的越界更新。

5.7 裁剪曲线图




图 5.1: 令 $|\hat{A}| = 1$ 时, PPO 单样本裁剪目标随概率比的变化。

5.8 为什么说它是“悲观替代目标”

对任意样本,

$$\min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \leq r_t \hat{A}_t. \quad (5.15)$$

因此 L^{CLIP} 是未裁剪替代目标 L^{CPI} 的逐样本下界。它在可能因概率变化过大而获得额外“乐观收益”时采用较保守值。

容易混淆的地方

这里的“下界”只指裁剪目标不超过未裁剪的样本替代目标。它不是新策略真实期望回报 $J(\theta)$ 的严格下界, 也不自动保证每次更新后真实回报单调增加。PPO 是受 TRPO 启发的实用一阶方法, 而非 TRPO 理论保证的完全等价实现。

5.9 为什么在旧策略处保持相同一阶梯度

当 $\theta = \theta_{\text{old}}$ 时, $r_t = 1$, 位于裁剪区间内部。此时

$$\ell_t^{\text{CLIP}}(r_t) = r_t \hat{A}_t, \quad (5.16)$$

所以局部一阶梯度与普通策略梯度一致。裁剪只在策略离开旧策略一定距离后改变目标形状。

5.10 概率比与对数概率差

数值实现通常不直接相除, 而是使用

$$\log r_t(\theta) = \log \pi_\theta(a_t | s_t) - \log \pi_{\theta_{\text{old}}}(a_t | s_t), \quad (5.17)$$

再计算

$$r_t(\theta) = \exp(\log r_t(\theta)). \quad (5.18)$$

对数空间更稳定，也便于处理语言模型中很小的 token 概率。

PPO 的完整训练目标与实现流程

6.1 策略项、价值项与熵项

PPO 的常见组合最大化目标为

$$J_{\text{PPO}}(\theta, \psi) = \hat{\mathbb{E}}_t [\ell_t^{\text{CLIP}}(\theta) - c_V \mathcal{L}_{V,t}(\psi) + c_H \mathcal{H}(\pi_\theta(\cdot | s_t))] . \quad (6.1)$$

本节新符号

θ	策略模型参数。
ψ	价值模型参数；若共享骨干网络，部分参数可能重合。
$c_V \geq 0$	价值损失权重。
$c_H \geq 0$	熵奖励权重。
$\mathcal{H}(\pi)$	策略熵，用于鼓励探索。

离散动作策略的熵为

$$\mathcal{H}(\pi_\theta(\cdot | s)) = - \sum_a \pi_\theta(a | s) \log \pi_\theta(a | s). \quad (6.2)$$

分布越均匀，熵越高；过早坍缩到少数动作时，熵下降。最大化熵项可缓解探索不足。

优化器通常最小化损失，因此代码中常写为

$$\mathcal{L}_{\text{total}} = -L^{\text{CLIP}} + c_V \mathcal{L}_V - c_H \mathcal{H}. \quad (6.3)$$

符号不同只是“最大化目标”与“最小化损失”的约定差异。

6.2 价值函数裁剪

部分实现也裁剪价值更新。令

$$V_t^{\text{clip}} = V_{\psi_{\text{old}}}(s_t) + \text{clip}\left(V_{\psi}(s_t) - V_{\psi_{\text{old}}}(s_t), -\epsilon_V, \epsilon_V\right), \quad (6.4)$$

则可定义

$$\mathcal{L}_{V,t} = \max\left[\left(V_{\psi}(s_t) - \hat{V}_t^{\text{target}}\right)^2, \left(V_t^{\text{clip}} - \hat{V}_t^{\text{target}}\right)^2\right]. \quad (6.5)$$

取较大误差是保守做法，防止价值网络通过一次大幅变化获得看似更低的回归误差。价值裁剪不是 PPO 原理中不可缺少的部分，不同实现可能采用普通均方误差。

6.3 优势标准化

小批次中常使用

$$\tilde{A}_t = \frac{\hat{A}_t - \text{mean}(\hat{A})}{\text{std}(\hat{A}) + \epsilon_{\text{num}}}, \quad (6.6)$$

其中 $\epsilon_{\text{num}} > 0$ 是防止除零的数值稳定常数。标准化改变有限批次估计器的缩放与一定统计性质，但通常使不同批次的梯度尺度更稳定。

6.4 PPO 的完整算法

1. 保存旧策略参数： $\theta_{\text{old}} \leftarrow \theta$ 。
2. 用 $\pi_{\theta_{\text{old}}}$ 采集 N 条轨迹或 $N \times T$ 个时间步。
3. 保存每个已采动作的旧对数概率 $\log \pi_{\theta_{\text{old}}}(a_t | s_t)$ 。
4. 根据奖励与旧价值预测计算 TD error 和 GAE 优势 $\hat{A}_t$ 。
5. 计算价值回归目标 $\hat{V}_t^{\text{target}}$ 。
6. 将整批数据随机打乱，划分为若干 minibatch。
7. 对同一批数据执行 K 个 epoch：重新计算当前对数概率、概率比、裁剪策略损失、价值损失和熵项，并执行梯度更新。
8. 可监控新旧策略的近似 KL；若超过阈值，可提前停止当前批次的多轮更新。
9. 丢弃该批数据，使用更新后的策略重新采样。

Listing 6.1: PPO 的概念伪代码

```
for iteration in range(num_iterations):
    old_policy = snapshot(policy)
```

```

batch = rollout(old_policy, environment)
# batch stores states, actions, rewards, dones and old_log_probs

advantages, value_targets = compute_gae(
    rewards=batch.rewards,
    values=value_model(batch.states),
    dones=batch.dones,
    gamma=gamma,
    lam=lam,
)

for epoch in range(update_epochs):
    for minibatch in shuffle_and_split(batch):
        new_log_probs = policy.log_prob(
            minibatch.actions, minibatch.states
        )
        ratio = exp(new_log_probs - minibatch.old_log_probs)

        unclipped = ratio * minibatch.advantages
        clipped = clip(ratio, 1-epsilon, 1+epsilon) \
            * minibatch.advantages
        policy_loss = -mean(min(unclipped, clipped))

        value_loss = mse(
            value_model(minibatch.states),
            minibatch.value_targets,
        )
        entropy = policy.entropy(minibatch.states).mean()

        total_loss = policy_loss \
            + c_v * value_loss \
            - c_h * entropy
        optimizer.zero_grad()
        total_loss.backward()
        optimizer.step()

```

6.5 一个单样本数值例子

设 $\epsilon = 0.2$ 。

数值例子

若 $\hat{A} = 2$ ，旧策略概率为 0.10，当前概率为 0.15，则

$$r = 0.15/0.10 = 1.5.$$

未裁剪项为 $1.5 \times 2 = 3$ ；裁剪项为 $1.2 \times 2 = 2.4$ ；取最小值得 2.4。这个样本不会继续奖励把好动作概率从 1.2 倍推到 1.5 倍。

数值例子

若 $\hat{A} = -2$ ，旧策略概率为 0.10，当前概率为 0.05，则

$$r = 0.5.$$

未裁剪项为 $0.5 \times (-2) = -1$ ；裁剪项为 $0.8 \times (-2) = -1.6$ ；取最小值得 -1.6 。最大化目标时，继续把概率从 0.8 倍降到 0.5 倍不会获得额外收益。

6.6 裁剪并不等于概率真的被限制在区间内

PPO 裁剪的是目标函数中的激励，不是对参数或概率施加硬约束。由于一个参数同时影响许多状态和动作，即使某个样本进入平坦区，其他样本的梯度仍可能使它的概率比继续变化。因此实践中仍需监控 KL、梯度范数与 clip fraction。

本节新符号

clip fraction	批次中进入裁剪区域的样本比例，通常统计满足 $ r_t - 1 > \epsilon$ 的比例。
approx KL	用样本近似的新旧策略 KL，用于判断整体更新是否过大。

PPO 在大语言模型 RLHF 中的形式

7.1 语言模型如何对应 MDP

给定提示词 x ，回答为 token 序列

$$y = (y_1, y_2, \dots, y_T). \quad (7.1)$$

自回归策略为

$$\pi_{\theta}(y \mid x) = \prod_{t=1}^T \pi_{\theta}(y_t \mid x, y_{<t}), \quad (7.2)$$

因此

$$\log \pi_{\theta}(y \mid x) = \sum_{t=1}^T \log \pi_{\theta}(y_t \mid x, y_{<t}). \quad (7.3)$$

本节新符号

x	提示词或问题。
y	完整回答。
y_t	回答中的第 t 个 token。
$y_{<t}$	第 t 个 token 之前的回答前缀。
$T = y $	回答 token 数量。

状态是 $(x, y_{<t})$ ，动作是 y_t 。环境转移近似为确定性：选定 token 后，它被迫加到前缀。终止动作通常是 EOS 或达到最大长度。

7.2 奖励模型与参考策略

标准 RLHF PPO 通常涉及四类模型：

表 7.1: LLM PPO 中模型的角色

模型	作用	是否训练
策略模型 π_θ	生成回答，是最终需要优化的 actor	是
价值模型 V_ψ	预测前缀的未来回报，构造优势	是
奖励模型 $r_\phi(x, y)$	对完整回答或过程步骤给分	通常在 PPO 阶段冻结
参考模型 π_{ref}	表示希望不要偏离太远的初始 SFT 行为	冻结

容易混淆的地方

$\pi_{\theta_{\text{old}}}$ 与 π_{ref} 不是同一个概念。旧策略是“生成当前训练批次的策略”，每轮采样后更新，用于重要性比；参考策略通常是固定的 SFT 模型，用于长期 KL 正则化。实现中它们偶尔可能在某一时刻参数相同，但职责不同。

7.3 KL 正则化奖励

奖励模型可能只在完整回答结束时给出标量 $r_\phi(x, y)$ 。为了约束策略偏离参考模型，常把每个 token 的 KL 近似惩罚加入奖励：

$$r_t^{\text{KL}} = -\beta [\log \pi_\theta(y_t | x, y_{<t}) - \log \pi_{\text{ref}}(y_t | x, y_{<t})], \quad (7.4)$$

其中 $\beta > 0$ 是 KL 系数。终止 token 还会获得奖励模型分数：

$$r_t = \begin{cases} r_t^{\text{KL}}, & t < T, \\ r_T^{\text{KL}} + r_\phi(x, y), & t = T. \end{cases} \quad (7.5)$$

对序列求和：

$$\sum_{t=1}^T r_t^{\text{KL}} = -\beta \sum_{t=1}^T \log \frac{\pi_\theta(y_t | x, y_{<t})}{\pi_{\text{ref}}(y_t | x, y_{<t})} \quad (7.6)$$

$$= -\beta \log \frac{\pi_\theta(y | x)}{\pi_{\text{ref}}(y | x)}. \quad (7.7)$$

对 $y \sim \pi_\theta$ 求期望得到

$$-\beta D_{\text{KL}}(\pi_\theta(\cdot | x) \| \pi_{\text{ref}}(\cdot | x)). \quad (7.8)$$

因此 token 级对数概率差的累计，正对应序列分布上的 KL 正则项。

7.4 LLM PPO 目标

用旧策略对提示词 x 生成回答 y ，在 token 级定义

$$r_t^{\text{old} \rightarrow \text{new}}(\theta) = \frac{\pi_{\theta}(y_t \mid x, y_{<t})}{\pi_{\theta_{\text{old}}}(y_t \mid x, y_{<t})}. \quad (7.9)$$

PPO 策略目标为

$$J_{\text{PPO}}(\theta) = \mathbb{E} \left[\frac{1}{T} \sum_{t=1}^T \min \left(r_t^{\text{old} \rightarrow \text{new}}(\theta) \hat{A}_t, \text{clip}(r_t^{\text{old} \rightarrow \text{new}}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]. \quad (7.10)$$

优势 $\hat{A}_t$ 由奖励模型分数、KL 惩罚和价值模型通过 GAE 得到。

7.5 为什么 LLM PPO 显存开销大

训练时通常需要同时驻留或分阶段运行：

- 可训练策略模型及其优化器状态、梯度、激活；
- 可训练价值模型及其优化器状态、梯度、激活；
- 冻结参考模型；
- 冻结奖励模型；
- 生成阶段的 KV cache 与轨迹缓存。

价值模型往往与策略模型规模相当。GRPO 的核心动机之一就是去掉这个单独的价值模型，以组内相对奖励近似优势 [8]。

第三部分

GRPO：用组内相对奖励替代价值模型

从 PPO 到 GRPO

8.1 GRPO 改变了 PPO 的哪一部分

PPO 的策略更新需要优势 $\hat{A}_t$ 。在 actor-critic PPO 中，优势通常依赖价值模型 V_ψ ：

$$\hat{A}_t \approx r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t) + \dots \quad (8.1)$$

GRPO（Group Relative Policy Optimization）保留 PPO 的以下结构：

- 用旧策略采样；
- 使用当前策略与旧策略的 token 概率比；
- 使用 PPO 式裁剪替代目标；
- 使用参考模型进行 KL 正则化。

它主要替换了**优势估计方法**：对同一个问题一次采样多个回答，用这些回答的组内相对得分构造优势，不再训练单独的价值模型 [8]。




图 8.1: PPO 与 GRPO 的核心结构差异：GRPO 用同题多回答的相对得分替代价值模型。

8.2 组采样

从问题分布 $P(Q)$ 中采样问题 q 。对同一个 q ，使用旧策略独立采样 G 个回答：

$$o_i \sim \pi_{\theta_{\text{old}}}(\cdot | q), \quad i = 1, \dots, G. \quad (8.2)$$

奖励函数或奖励模型为每个回答给出标量分数：

$$r_i = R(q, o_i). \quad (8.3)$$

本节新符号

q	一个问题或提示词。
G	每个问题采样的回答数量，即 group size。
o_i	同一问题的第 i 个回答，长度为 $ o_i $ 。
$o_{i,t}$	第 i 个回答的第 t 个 token。
r_i	第 i 个回答的标量奖励。

组均值和组标准差定义为

$$\bar{r} = \frac{1}{G} \sum_{j=1}^G r_j, \quad (8.4)$$

$$s_r = \sqrt{\frac{1}{G} \sum_{j=1}^G (r_j - \bar{r})^2}. \quad (8.5)$$

原始 GRPO 的 outcome supervision 优势写为

$$\hat{A}_i = \frac{r_i - \bar{r}}{s_r}. \quad (8.6)$$

数值实现中通常写为

$$\hat{A}_i = \frac{r_i - \bar{r}}{s_r + \epsilon_{\text{num}}} \quad (8.7)$$

以避免所有奖励相同时除以零。

8.3 为什么相对奖励可以充当基线

若只减均值而不除标准差：

$$A_i^{\text{center}} = r_i - \bar{r}. \quad (8.8)$$

它表达了“该回答比同题其他回答的平均水平高多少”。在同一个问题内部，问题难度、奖励尺度等共同因素会部分抵消。例如，一个难题所有回答得分都较低，但其中相对更好的回答仍可获得正优势。

减均值后自动满足

$$\frac{1}{G} \sum_{i=1}^G A_i^{\text{center}} = 0. \quad (8.9)$$

再除以标准差后，若 $s_r > 0$ ，则组内优势具有约为单位尺度：

$$\frac{1}{G} \sum_{i=1}^G \hat{A}_i^2 = 1. \quad (8.10)$$

这有助于稳定不同问题、不同批次之间的梯度尺度。

直觉解释

PPO 的价值模型试图回答：“从这个前缀开始，平均能得到多少奖励？”GRPO 不显式预测这个绝对期望，而是对同一个问题现场采样多个回答，用它们的平均表现作为局部参照。它更像同场考试中的相对排名。

8.4 严格无偏基线与 GRPO 组均值的区别

这是理解 GRPO 时非常重要的细节。先考虑最简单的一步决策，记

$$z_i = \nabla_{\theta} \log \pi_{\theta}(a_i), \quad (8.11)$$

其中 a_i 是第 i 个独立样本，对应奖励 r_i 。真实策略梯度为

$$g = \mathbb{E}[z_i r_i]. \quad (8.12)$$

若使用包含样本自身的组均值

$$\bar{r} = \frac{1}{G} \sum_{j=1}^G r_j, \quad (8.13)$$

梯度估计器为

$$\hat{g}_{\text{mean}} = \frac{1}{G} \sum_{i=1}^G z_i (r_i - \bar{r}). \quad (8.14)$$

求期望。第一部分为

$$\mathbb{E} \left[\frac{1}{G} \sum_i z_i r_i \right] = g. \quad (8.15)$$

第二部分中,

$$\mathbb{E}[z_i \bar{r}] = \frac{1}{G} \mathbb{E} \left[z_i r_i + \sum_{j \neq i} z_i r_j \right] \quad (8.16)$$

$$= \frac{1}{G} \mathbb{E}[z_i r_i] + \frac{1}{G} \sum_{j \neq i} \mathbb{E}[z_i] \mathbb{E}[r_j]. \quad (8.17)$$

因为

$$\mathbb{E}[z_i] = \sum_a \pi_\theta(a) \nabla_\theta \log \pi_\theta(a) = \nabla_\theta \sum_a \pi_\theta(a) = 0, \quad (8.18)$$

交叉项为零, 因此

$$\mathbb{E}[z_i \bar{r}] = \frac{1}{G} g. \quad (8.19)$$

最终

$$\mathbb{E}[\hat{g}_{\text{mean}}] = \left(1 - \frac{1}{G}\right) g. \quad (8.20)$$

也就是说, 包含自身奖励的组均值会带来一个收缩因子。若没有标准差归一化, 乘以 $G/(G-1)$ 可校正这个常数偏差。

若使用 leave-one-out 基线

$$\bar{r}_{-i} = \frac{1}{G-1} \sum_{j \neq i} r_j, \quad (8.21)$$

则 $\bar{r}_{-i}$ 与当前动作 a_i 独立, 满足

$$\mathbb{E}[z_i \bar{r}_{-i}] = \mathbb{E}[z_i] \mathbb{E}[\bar{r}_{-i}] = 0, \quad (8.22)$$

从而得到严格无偏估计。这是 RLOO 与“包含自身的组均值”之间的关键区别。

容易混淆的地方

原始 GRPO 进一步除以随机的组标准差 s_r 。由于 s_r 同样依赖所有样本, 包括当前样本, 通常不能把它视为与动作独立的常数, 因此估计器不再只是简单的常数缩放。GRPO 的组内标准化优势应理解为实用的、低方差的相对学习信号, 而不是严格无偏策略梯度的直接替代。

这并不意味着 GRPO “错误”。深度强化学习中的许多优势标准化、裁剪和多轮 off-policy 更新都引入近似或偏差, 实际目标是在可接受偏差下显著降低方差、显存和训练不稳定性。

8.5 Outcome supervision 下的 token 优势

若奖励只在完整回答结束后给出, GRPO 把回答级归一化奖励广播给该回答所有 token:

$$\hat{A}_{i,t} = \hat{A}_i = \frac{r_i - \bar{r}}{s_r + \epsilon_{\text{num}}}, \quad t = 1, \dots, |o_i|. \quad (8.23)$$

这相当于认为：一条回答中的所有 token 共同对最终结果负责。它不需要价值模型，但信用分配较粗糙：一个长推理中可能只有少数关键步骤决定对错，所有 token 却得到相同符号和幅度的优势。

8.6 Process supervision 下的 token 优势

若过程奖励模型在第 j 个推理步骤结束处给出奖励 $r_i^{(j)}$ ，该步骤结束 token 索引为 $k_i^{(j)}$ ，先对过程奖励进行组内或批内归一化，记为 $\tilde{r}_i^{(j)}$ 。原始 DeepSeekMath 描述的 token 优势可写为

$$\hat{A}_{i,t} = \sum_{j: k_i^{(j)} \geq t} \tilde{r}_i^{(j)}. \quad (8.24)$$

即当前 token 的优势由其后所有步骤奖励之和决定。这类似 reward-to-go：较早 token 会影响后续更多步骤，因此接收更多未来奖励。

8.7 GRPO 的裁剪策略目标

对第 i 个回答的第 t 个 token，定义新旧策略概率比

$$\rho_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}. \quad (8.25)$$

GRPO 的 PPO 式策略项为

$$\ell_{i,t}^{\text{GRPO}}(\theta) = \min \left[\rho_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(\rho_{i,t}(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_{i,t} \right]. \quad (8.26)$$

对组、回答长度和问题取平均：

$$J_{\text{policy}}^{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \ell_{i,t}^{\text{GRPO}}(\theta) \right]. \quad (8.27)$$

这里 $1/|o_i|$ 表示每个回答先做 token 平均，使每条回答在组平均中近似同权。不同实现也可能按所有有效 token 统一平均，这会产生不同的长度权重。

8.8 GRPO 的 KL 正则项

原始 GRPO 把策略与参考策略的 KL 惩罚直接放入目标，而不是先混入奖励再计算优势：

$$J_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left(\ell_{i,t}^{\text{GRPO}}(\theta) - \beta \hat{D}_{i,t}^{\text{KL}} \right) \right]. \quad (8.28)$$

本节新符号

$\beta \geq 0$	GRPO 中参考策略 KL 惩罚系数。
$\hat{D}_{i,t}^{\text{KL}}$	在已采 token 上计算的 KL 样本估计。

把 KL 与优势分开有一个直接好处：组内相对奖励不会被 token 级 KL 项扰动，优势更清晰地反映任务奖励的相对差异。

GRPO 中 KL 估计器的推导

9.1 原始论文使用的正值估计器

记当前 token 分布为

$$p(a) = \pi_\theta(a \mid s), \quad (9.1)$$

参考 token 分布为

$$q(a) = \pi_{\text{ref}}(a \mid s). \quad (9.2)$$

对从 p 采样到的动作 a , 令

$$x = \frac{q(a)}{p(a)} > 0. \quad (9.3)$$

GRPO 使用

$$k(x) = x - \log x - 1 \quad (9.4)$$

作为单样本 KL 估计, 即

$$\hat{D}^{\text{KL}}(a) = \frac{q(a)}{p(a)} - \log \frac{q(a)}{p(a)} - 1. \quad (9.5)$$

9.2 为什么它逐样本非负

考虑函数

$$k(x) = x - \log x - 1, \quad x > 0. \quad (9.6)$$

一阶和二阶导数为

$$k'(x) = 1 - \frac{1}{x}, \quad (9.7)$$

$$k''(x) = \frac{1}{x^2} > 0. \quad (9.8)$$

所以 k 是严格凸函数, 唯一驻点在 $x = 1$, 且

$$k(1) = 1 - 0 - 1 = 0. \quad (9.9)$$

因此

$$k(x) \geq 0, \quad \text{且仅当 } x = 1 \text{ 时取 } 0. \quad (9.10)$$

这比简单使用 $\log p(a) - \log q(a)$ 更适合作为逐 token 惩罚, 因为后者单个样本可以为负, 而 $k(x)$ 每个样本都非负。

9.3 为什么其期望等于正向 KL

当动作确实从当前分布 p 采样时:

$$\mathbb{E}_{a \sim p}[k(q(a)/p(a))] = \sum_a p(a) \left[\frac{q(a)}{p(a)} - \log \frac{q(a)}{p(a)} - 1 \right] \quad (9.11)$$

$$= \sum_a q(a) - \sum_a p(a) \log \frac{q(a)}{p(a)} - \sum_a p(a) \quad (9.12)$$

$$= 1 + \sum_a p(a) \log \frac{p(a)}{q(a)} - 1 \quad (9.13)$$

$$= D_{\text{KL}}(p \| q). \quad (9.14)$$

因此它是 $D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}})$ 的无偏 Monte Carlo 估计器, 前提是采样分布就是当前 $p = \pi_\theta$ 。

容易混淆的地方

PPO/GRPO 的训练数据通常由旧策略 $\pi_{\theta_{\text{old}}}$ 生成, 而优化过程中当前策略 π_θ 已发生变化。若仍直接对旧样本使用该式, 它对当前 KL 的“严格无偏”性质不再自动成立。由于裁剪使新旧策略保持接近, 这一估计通常被作为近似使用; 严格校正需要额外重要性权重。

9.4 与常见对数比惩罚的关系

常见的单样本对数比为

$$\log \frac{p(a)}{q(a)}. \quad (9.15)$$

其在 $a \sim p$ 下的期望同样等于 $D_{\text{KL}}(p \| q)$, 但单个样本可正可负。 $k(x) = x - \log x - 1$ 在 $p \approx q$ 附近可用 Taylor 展开: 令 $x = 1 + u$, u 很小,

$$\log(1 + u) = u - \frac{u^2}{2} + O(u^3), \quad (9.16)$$

$$k(1 + u) = (1 + u) - \left(u - \frac{u^2}{2} + O(u^3) \right) - 1 \quad (9.17)$$

$$= \frac{u^2}{2} + O(u^3). \quad (9.18)$$

因此在两分布接近时, 它近似一个非负二次惩罚。

GRPO 的完整训练流程、数值例子与性质

10.1 完整流程

对每个训练迭代：

1. 从数据集采样一批问题 q 。
2. 保存旧策略 $\pi_{\theta_{\text{old}}}$ 。
3. 对每个问题从旧策略采样 G 个回答。
4. 用可验证规则、奖励模型或环境执行结果计算每个回答的奖励 r_i 。
5. 在每个问题的组内计算均值、标准差和相对优势。
6. 将 outcome 优势广播到回答内全部 token，或依据过程奖励构造 token 级优势。
7. 对同一批回答执行若干轮更新：计算当前/旧策略概率比、PPO 裁剪项和参考模型 KL 项。
8. 最大化 GRPO 目标，更新策略模型；不训练价值模型。
9. 重新采样新回答，进入下一轮。

Listing 10.1: Outcome-supervision GRPO 的概念伪代码

```
for iteration in range(num_iterations):
    old_policy = snapshot(policy)
    prompts = sample_prompts(batch_size)

    # Shape: [batch_size, group_size, sequence_length]
    completions = old_policy.generate(
        prompts, num_return_sequences=group_size
    )
    rewards = reward_fn(prompts, completions) # [B, G]

    group_mean = rewards.mean(dim=1, keepdim=True)
    group_std = rewards.std(dim=1, keepdim=True, unbiased=False)
    sequence_adv = (rewards - group_mean) / (group_std + eps_num)
```



```

# Broadcast each completion-level advantage to valid tokens.
token_adv = broadcast_to_tokens(sequence_adv, completions.mask)

for epoch in range(update_epochs):
    new_logp = policy.log_prob(completions)
    old_logp = old_policy.log_prob(completions).detach()
    ratio = exp(new_logp - old_logp)

    unclipped = ratio * token_adv
    clipped = clip(ratio, 1-epsilon, 1+epsilon) * token_adv
    policy_objective = minimum(unclipped, clipped)

    ref_logp = reference_policy.log_prob(completions).detach()
    x = exp(ref_logp - new_logp) # q(a) / p(a)
    kl_estimator = x - log(x) - 1

    objective = masked_mean(
        policy_objective - beta * kl_estimator,
        completions.mask,
    )
    loss = -objective
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

```

10.2 组内标准化数值例子

设同一个问题采样 $G = 4$ 个回答，奖励为

$$r = (1, 1, 0, -1). \quad (10.1)$$

组均值为

$$\bar{r} = \frac{1 + 1 + 0 - 1}{4} = 0.25. \quad (10.2)$$

按总体标准差定义：

$$s_r = \sqrt{\frac{(1 - 0.25)^2 + (1 - 0.25)^2 + (0 - 0.25)^2 + (-1 - 0.25)^2}{4}} \quad (10.3)$$

$$= \sqrt{0.6875} \approx 0.8292. \quad (10.4)$$

优势为

$$\hat{A} \approx (0.9045, 0.9045, -0.3015, -1.5076). \quad (10.5)$$

前两个回答被提高概率，第三个虽奖励为 0，但低于组均值，仍获得负优势；第四个受到最强抑制。

直觉解释

GRPO 学习的是“相对同组更好”，不是“奖励是否大于零”。奖励 0 的回答在较弱组里可能是正优势，在较强组里可能是负优势。

10.3 所有奖励相同时会发生什么

若 $r_1 = \dots = r_G = c$ ，则

$$\bar{r} = c, \quad s_r = 0, \quad (10.6)$$

所有中心化奖励都是零。这组数据没有提供“哪个回答更好”的信息。使用数值稳定项后，优势仍为零，策略项不给梯度，只剩 KL 正则项。实际实现可能跳过该组、增加采样多样性，或设计更细粒度奖励。

10.4 组大小 G 的作用

较大的 G 通常带来：

- 更稳定的组均值与标准差估计；
- 更高概率在同一问题上同时出现好回答和坏回答；
- 更丰富的相对排序信号；
- 更高生成成本、KV cache 和奖励评估成本。

包含自身均值造成的收缩因子 $1 - 1/G$ 会随 G 增大趋近 1，但标准差归一化与其他训练近似仍存在。

10.5 GRPO 的优势与代价

表 10.1: GRPO 相对 actor-critic PPO 的主要变化

方面	GRPO 的优势	GRPO 的代价或风险
模型数量	不需要单独价值模型, 减少显存和训练复杂度	需要同题多采样, 生成开销增大
优势估计	组内比较适合可验证奖励和同题候选比较	相对优势依赖组构成, 标准化引入偏差
信用分配	无需训练 token 级价值预测	outcome 奖励广播到全部 token, 信用分配粗糙
稳定性	保留 PPO 裁剪与参考策略 KL	若组内奖励方差为零或极小, 学习信号退化
奖励尺度	标准化减弱不同问题奖励尺度差异	绝对奖励幅度被抹去, 不同难度权重可能失真

10.6 PPO 与 GRPO 的关系总结

从公式结构看，GRPO 可以概括为

$$\text{GRPO} = \text{PPO-Clip} + \text{组内相对优势} - \text{价值模型} + \text{显式参考 KL 项}. \quad (10.7)$$

它不是从零开始完全不同的算法，而是 PPO 在 LLM 多候选生成场景中的一个特定 actor-only 变体。

第四部分

DPO：从 KL 正则化 RLHF 到二分类损失

偏好数据、奖励模型与标准 RLHF 目标

11.1 偏好数据的形式

DPO 使用离线偏好数据集

$$\mathcal{D} = \{(x^{(n)}, y_w^{(n)}, y_l^{(n)})\}_{n=1}^N. \quad (11.1)$$

本节新符号

$\mathcal{D}$	偏好数据集。
N	偏好样本数量。
x	提示词。
y_w	preferred/winner completion, 标注者更偏好的回答。
y_l	dispreferred/loser completion, 标注者较不偏好的回答。
$y_w > y_l \mid x$	在提示词 x 下, y_w 优于 y_l 。

偏好标签只告诉我们两个回答谁更好, 并没有直接给出绝对奖励分数。需要一个概率模型把潜在奖励与比较概率联系起来。

11.2 Bradley–Terry 偏好模型

设存在未知的真实奖励函数 $r^*(x, y)$ 。Bradley–Terry 模型假设

$$\mathbb{P}^*(y_1 > y_2 \mid x) = \frac{\exp(r^*(x, y_1))}{\exp(r^*(x, y_1)) + \exp(r^*(x, y_2))}. \quad (11.2)$$

把分子分母同时除以 $\exp(r^*(x, y_1))$:

$$\mathbb{P}^*(y_1 > y_2 | x) = \frac{1}{1 + \exp(r^*(x, y_2) - r^*(x, y_1))} \quad (11.3)$$

$$= \sigma(r^*(x, y_1) - r^*(x, y_2)), \quad (11.4)$$

其中 sigmoid 函数定义为

$$\sigma(z) = \frac{1}{1 + e^{-z}}. \quad (11.5)$$

直觉解释

偏好概率只取决于两个回答的奖励差，而不取决于奖励绝对零点。若 $r(y_1) = r(y_2)$ ，偏好概率为 0.5；差值越大，偏好 y_1 的概率越接近 1。

11.3 显式奖励模型的训练

用参数为 ϕ 的奖励模型 $r_\phi(x, y)$ 近似 r^* 。对已标注 $y_w > y_l$ 的样本，最大似然希望最大化

$$\sigma(r_\phi(x, y_w) - r_\phi(x, y_l)). \quad (11.6)$$

所以负对数似然损失为

$$\mathcal{L}_{\text{RM}}(\phi) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l))]. \quad (11.7)$$

标准 PPO-based RLHF 先训练该奖励模型，再用 PPO 优化策略，使生成回答获得更高奖励。

11.4 KL 正则化的 RLHF 目标

对每个提示词 x ，标准目标可以写为

$$\max_{\pi} \mathbb{E}_{x \sim \mathcal{D}_x} [\mathbb{E}_{y \sim \pi(\cdot | x)} [r(x, y)] - \beta D_{\text{KL}}(\pi(\cdot | x) \| \pi_{\text{ref}}(\cdot | x))]. \quad (11.8)$$

本节新符号

$\mathcal{D}_x$	提示词分布或提示词数据集。
π	待优化策略；暂时把它看作任意条件概率分布，而不限定参数化形式。
$r(x, y)$	回答的奖励函数，可来自奖励模型。
$\pi_{\text{ref}}(y x)$	参考策略，通常是 SFT 模型。
$\beta > 0$	KL 正则系数。越大，偏离参考策略的代价越高。

对固定 x 展开：

$$J_x(\pi) = \sum_y \pi(y | x) r(x, y) \quad (11.9)$$

$$- \beta \sum_y \pi(y | x) \log \frac{\pi(y | x)}{\pi_{\text{ref}}(y | x)}. \quad (11.10)$$

第一项追求高奖励，第二项约束模型不要远离参考分布。若没有 KL 项，策略可能把全部概率集中在奖励模型偶然高估的少数回答上，产生 reward hacking 或模式坍塌。

11.5 为什么 DPO 从这个目标出发

DPO 的关键观察是：这个 KL 正则化优化问题对“策略分布本身”存在闭式最优解。若能把奖励写成最优策略与参考策略的函数，再代回 Bradley–Terry 偏好模型，就可以直接用策略参数拟合偏好数据，不必显式训练奖励模型后再运行 PPO [7]。

KL 正则化目标的闭式最优策略

12.1 固定一个提示词进行优化

为简化记号，固定 x ，写

$$\pi_y = \pi(y \mid x), \quad (12.1)$$

$$\pi_{\text{ref},y} = \pi_{\text{ref}}(y \mid x), \quad (12.2)$$

$$r_y = r(x, y). \quad (12.3)$$

目标为

$$\max_{\{\pi_y\}} \left\{ \sum_y \pi_y r_y - \beta \sum_y \pi_y \log \frac{\pi_y}{\pi_{\text{ref},y}} \right\}, \quad (12.4)$$

约束为

$$\pi_y \geq 0, \quad \sum_y \pi_y = 1. \quad (12.5)$$

假设参考策略在考虑的回答上概率为正，最优策略也位于分布内部，可以使用拉格朗日乘子处理归一化约束。

12.2 构造拉格朗日函数

引入标量乘子 λ ：

$$\mathcal{J}(\pi, \lambda) = \sum_y \pi_y r_y - \beta \sum_y \pi_y \log \frac{\pi_y}{\pi_{\text{ref},y}} + \lambda \left(\sum_y \pi_y - 1 \right). \quad (12.6)$$

本节新符号

λ 拉格朗日乘子，用来强制满足 $\sum_y \pi_y = 1$ 。

对每个 π_y 求偏导。注意

$$\frac{\partial}{\partial \pi_y} \left[\pi_y \log \frac{\pi_y}{\pi_{\text{ref},y}} \right] = \log \frac{\pi_y}{\pi_{\text{ref},y}} + 1. \quad (12.7)$$

因此

$$\frac{\partial \mathcal{J}}{\partial \pi_y} = r_y - \beta \left(\log \frac{\pi_y}{\pi_{\text{ref},y}} + 1 \right) + \lambda. \quad (12.8)$$

令其为零：

$$r_y - \beta \log \frac{\pi_y}{\pi_{\text{ref},y}} - \beta + \lambda = 0. \quad (12.9)$$

移项并除以 β ：

$$\log \frac{\pi_y}{\pi_{\text{ref},y}} = \frac{r_y}{\beta} + \frac{\lambda}{\beta} - 1. \quad (12.10)$$

两边取指数：

$$\pi_y = \pi_{\text{ref},y} \exp \left(\frac{r_y}{\beta} \right) \exp \left(\frac{\lambda}{\beta} - 1 \right). \quad (12.11)$$

最后一个指数因子与 y 无关，只负责归一化。定义配分函数

$$Z(x) = \sum_y \pi_{\text{ref}}(y | x) \exp \left(\frac{r(x, y)}{\beta} \right). \quad (12.12)$$

由 $\sum_y \pi_y = 1$ ，得到

$$\exp \left(\frac{\lambda}{\beta} - 1 \right) = \frac{1}{Z(x)}. \quad (12.13)$$

因此闭式最优策略为

$$\pi_r^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp \left(\frac{r(x, y)}{\beta} \right). \quad (12.14)$$

直觉解释

最优策略等于“参考策略概率”乘以“奖励的指数权重”，再归一化。高奖励回答被上调，但参考策略原本概率极低的回答不会毫无代价地获得巨概率。 β 控制指数重加权的温度： β 越小，奖励差被放大； β 越大，策略越接近参考策略。

12.3 验证这是最大值而不是最小值

目标关于 π 的二阶导数为

$$\frac{\partial^2 \mathcal{J}}{\partial \pi_y^2} = -\frac{\beta}{\pi_y} < 0, \quad (12.15)$$

交叉二阶导数为零。因此在概率单纯形内部，目标对 π 严格凹，驻点是唯一全局最大值。

12.4 从最优策略反解奖励

从

$$\pi_r^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) \exp\left(\frac{r(x, y)}{\beta}\right) \quad (12.16)$$

出发，取对数：

$$\log \pi_r^*(y | x) = \log \pi_{\text{ref}}(y | x) + \frac{r(x, y)}{\beta} - \log Z(x). \quad (12.17)$$

整理：

$$r(x, y) = \beta \log \frac{\pi_r^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x). \quad (12.18)$$

这表示：一个最优策略相对参考策略的对数概率增量，可以被解释为隐式奖励，再加上只依赖提示词的常数。

12.5 为什么仅依赖提示词 x 的常数不影响偏好

对同一个提示词的两个回答 y_1, y_2 ，奖励差为

$$r(x, y_1) - r(x, y_2) = \beta \log \frac{\pi_r^*(y_1 | x)}{\pi_{\text{ref}}(y_1 | x)} \quad (12.19)$$

$$- \beta \log \frac{\pi_r^*(y_2 | x)}{\pi_{\text{ref}}(y_2 | x)} \quad (12.20)$$

$$+ \beta \log Z(x) - \beta \log Z(x) \quad (12.21)$$

$$= \beta \left[\log \frac{\pi_r^*(y_1 | x)}{\pi_{\text{ref}}(y_1 | x)} - \log \frac{\pi_r^*(y_2 | x)}{\pi_{\text{ref}}(y_2 | x)} \right]. \quad (12.22)$$

配分函数完全抵消。

为什么可以这样做

Bradley–Terry 模型只使用奖励差，因此无法识别“对同一提示词的所有回答统一加上一个常数”。DPO 正好利用这种不可辨识性：虽然 $Z(x)$ 很难计算，但它只产生一个与回答无关的项，在偏好概率中会消失。

DPO 损失函数的逐步推导

13.1 把隐式奖励代入偏好概率

Bradley–Terry 模型给出

$$\mathbb{P}(y_w > y_l | x) = \sigma(r(x, y_w) - r(x, y_l)). \quad (13.1)$$

用参数化策略 π_θ 代替未知最优策略 π_r^* ，定义隐式奖励

$$\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y | x)}{\pi_{\text{ref}}(y | x)}. \quad (13.2)$$

注意省略了 $\beta \log Z(x)$ ，因为它对同一 x 的奖励差无影响。

于是模型预测的偏好概率为

$$\mathbb{P}_\theta(y_w > y_l | x) = \sigma(\hat{r}_\theta(x, y_w) - \hat{r}_\theta(x, y_l)) \quad (13.3)$$

$$= \sigma\left(\beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)}\right). \quad (13.4)$$

定义 DPO logit

$$z_\theta(x, y_w, y_l) = \beta \left[\log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right]. \quad (13.5)$$

13.2 最大似然得到 DPO 损失

偏好标签为“winner 胜出”，其似然为 $\sigma(z_\theta)$ 。最大化数据似然等价于最小化负对数似然：

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} [\log \sigma(z_\theta(x, y_w, y_l))]. \quad (13.6)$$

展开为最常见公式：

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{\mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right]. \quad (13.7)$$

这就是 DPO 原论文的核心目标 [7]。

13.3 为什么不能只最大化 winner 的概率

一个朴素做法是只最小化

$$-\log \pi_{\theta}(y_w | x), \quad (13.8)$$

即 preferred SFT。它没有显式利用 loser，也无法表达“winner 相对 loser 好多少”。另一个朴素做法是最大化

$$\log \pi_{\theta}(y_w | x) - \log \pi_{\theta}(y_l | x), \quad (13.9)$$

但它缺少参考策略校正，可能通过极端降低 loser 概率或整体偏离初始模型来无界增大间隔。

DPO 使用

$$\log \frac{\pi_{\theta}(y | x)}{\pi_{\text{ref}}(y | x)} \quad (13.10)$$

衡量相对参考模型的变化，并通过 sigmoid 交叉熵使已正确、置信度较高的样本梯度自然衰减。

13.4 序列概率如何计算

对回答 $y = (y_1, \dots, y_T)$ ：

$$\log \pi_{\theta}(y | x) = \sum_{t=1}^T \log \pi_{\theta}(y_t | x, y_{<t}). \quad (13.11)$$

因此 DPO 的 winner 隐式奖励为

$$\hat{r}_{\theta}(x, y_w) = \beta \sum_{t=1}^{T_w} [\log \pi_{\theta}(y_{w,t} | x, y_{w,<t}) - \log \pi_{\text{ref}}(y_{w,t} | x, y_{w,<t})]. \quad (13.12)$$

loser 同理。训练时只对回答 token 计算 log probability，通常不把提示词 token 纳入序列对数概率。

容易混淆的地方

DPO 默认使用序列 log probability 的求和，因此长度会影响数值尺度：更长回答包含更多 token 对数概率差。是否做长度归一化属于算法变体或实现选择，不是原始 DPO 推导的一部分。随意除以长度会改变隐式奖励参数化，不能再声称与原始 KL 正则化目标完全相同。

13.5 DPO 梯度的完整推导

对单个样本，记

$$\ell(\theta) = -\log \sigma(z_\theta). \quad (13.13)$$

先求对 z 的导数。因为

$$\frac{d}{dz} \log \sigma(z) = 1 - \sigma(z) = \sigma(-z), \quad (13.14)$$

所以

$$\frac{d\ell}{dz} = -\sigma(-z). \quad (13.15)$$

再求 z_θ 的梯度。参考策略被冻结，与 θ 无关：

$$\nabla_\theta z_\theta = \beta [\nabla_\theta \log \pi_\theta(y_w | x) - \nabla_\theta \log \pi_\theta(y_l | x)]. \quad (13.16)$$

链式法则得到

$$\nabla_\theta \ell(\theta) = -\beta \sigma(-z_\theta) [\nabla_\theta \log \pi_\theta(y_w | x) - \nabla_\theta \log \pi_\theta(y_l | x)]. \quad (13.17)$$

对数据集取期望：

$$\nabla_\theta \mathcal{L}_{\text{DPO}} = -\beta \mathbb{E}_{\mathcal{D}} [\sigma(-z_\theta) (\nabla_\theta \log \pi_\theta(y_w | x) - \nabla_\theta \log \pi_\theta(y_l | x))]. \quad (13.18)$$

因为

$$-z_\theta = \hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w), \quad (13.19)$$

权重也可写为

$$\sigma(\hat{r}_\theta(x, y_l) - \hat{r}_\theta(x, y_w)). \quad (13.20)$$

13.6 梯度权重的含义

- 若模型错误地认为 loser 的隐式奖励更高，则 $z_\theta < 0$ ， $\sigma(-z_\theta)$ 接近 1，更新权重大。
- 若 winner 只略高于 loser，则 $z_\theta \approx 0$ ，权重约为 0.5。
- 若模型已经正确且高置信度地区分 winner， $z_\theta \gg 0$ ，权重接近 0，该样本梯度自然衰减。

因此 DPO 不只是“提高 winner、降低 loser”，还会根据当前隐式奖励排序错误程度动态加权样本。

13.7 beta 参数的双重解释

从原始 RLHF 目标看， β 是 KL 惩罚系数：

$$\mathbb{E}[r] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}). \quad (13.21)$$

较大 β 意味着最优策略更接近参考策略。闭式解中

$$\pi^*(y | x) \propto \pi_{\text{ref}}(y | x) e^{r(x,y)/\beta}, \quad (13.22)$$

也能看到较大 β 会减弱奖励重加权。

在 DPO 损失的 logit 中， β 又直接乘在 log-ratio 差上。不能只根据这个表面形式得出“ β 越大更新越激进”的简单结论：理论最优关系要求在较大 β 下，用更小的策略 log-ratio 差表达相同奖励差。实际训练中的作用还与学习率、数据可分性和模型容量耦合。

DPO 的实现、数值例子与假设边界

14.1 概念伪代码

Listing 14.1: DPO 训练的概念伪代码

```
for batch in preference_loader:
    # batch contains prompt, chosen response and rejected response
    pi_logp_w = policy.sequence_log_prob(
        batch.prompt, batch.chosen
    )
    pi_logp_l = policy.sequence_log_prob(
        batch.prompt, batch.rejected
    )

    with no_grad():
        ref_logp_w = reference.sequence_log_prob(
            batch.prompt, batch.chosen
        )
        ref_logp_l = reference.sequence_log_prob(
            batch.prompt, batch.rejected
        )

    winner_log_ratio = pi_logp_w - ref_logp_w
    loser_log_ratio = pi_logp_l - ref_logp_l
    logits = beta * (winner_log_ratio - loser_log_ratio)

    loss = -log_sigmoid(logits).mean()
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()
```

参考模型完全冻结。与 PPO/GRPO 不同，DPO 训练循环中不需要用当前策略在线生成回答，也不需要奖励模型前向打分或环境交互；它直接读取固定偏好对。

14.2 数值例子

设 $\beta = 0.1$ ，某个样本满足

$$\log \pi_{\theta}(y_w | x) = -8.0, \quad \log \pi_{\text{ref}}(y_w | x) = -8.5, \quad (14.1)$$

$$\log \pi_{\theta}(y_l | x) = -7.5, \quad \log \pi_{\text{ref}}(y_l | x) = -7.4. \quad (14.2)$$

则 winner 相对参考模型的 log-ratio 为

$$-8.0 - (-8.5) = 0.5, \quad (14.3)$$

loser 的 log-ratio 为

$$-7.5 - (-7.4) = -0.1. \quad (14.4)$$

DPO logit 为

$$z = 0.1 \times (0.5 - (-0.1)) = 0.06. \quad (14.5)$$

模型预测 winner 胜出的概率为

$$\sigma(0.06) \approx 0.515. \quad (14.6)$$

单样本损失为

$$-\log 0.515 \approx 0.663. \quad (14.7)$$

因为置信度不高，梯度权重

$$\sigma(-0.06) \approx 0.485 \quad (14.8)$$

仍较大，会继续提高 winner 相对参考模型的概率增量，并降低 loser 的相对增量。

14.3 DPO 与“训练一个隐式奖励模型”

定义

$$\hat{r}_{\theta}(x, y) = \beta \log \frac{\pi_{\theta}(y | x)}{\pi_{\text{ref}}(y | x)}. \quad (14.9)$$

DPO 损失恰好是以 $\hat{r}_{\theta}$ 为奖励参数化的 Bradley–Terry 奖励模型损失：

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} [\log \sigma(\hat{r}_{\theta}(x, y_w) - \hat{r}_{\theta}(x, y_l))]. \quad (14.10)$$

区别是这个“奖励模型”不能任意独立变化，它被约束为当前策略相对参考策略的 log-ratio。每次更新隐式奖励的同时，也直接更新了对应策略。

14.4 DPO 等价成立依赖的关键假设

1. **KL 正则化目标。** 推导从 $\mathbb{E}[r] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}})$ 出发；换成其他散度或约束，闭式关系会改变。

2. **Bradley–Terry 或兼容偏好模型。**偏好概率由奖励差通过 sigmoid 给出。标注噪声、非传递偏好或上下文效应可能违背该模型。
3. **参考策略支持集。**若 $\pi_{\text{ref}}(y | x) = 0$ 而目标策略希望给正概率，log-ratio 不可定义。神经语言模型 softmax 通常理论上对所有 token 给正概率，但数值截断与数据处理仍需注意。
4. **离线数据覆盖。**DPO 只学习数据集中出现的回答对；当前策略更新后会访问哪些新回答，不会自动获得在线反馈。
5. **模型表达能力与优化。**闭式最优策略存在于所有分布构成的空间中，但参数化神经网络未必能精确表示它，训练也未必达到全局最优。

容易混淆的地方

“DPO 不使用强化学习算法”是工程流程描述：它使用固定数据和普通反向传播，不进行在线 rollout 和策略梯度估计。但 DPO 的目标来自 KL 正则化强化学习问题的解析重参数化。称其为“完全与强化学习无关”并不准确。

14.5 离线 DPO 的分布偏移问题

偏好数据通常由某个行为策略 π_{data} 生成。训练后策略 π_{θ} 可能偏离该数据分布，而偏好标签只覆盖原有候选。DPO 不会自动评估新策略在分布外生成的回答，因此可能出现：

- 对训练偏好对拟合良好，但在线生成质量不成比例地提升；
- 利用数据集中的长度、格式或风格偏差；
- 对未覆盖主题的偏好泛化不足。

这不是公式推导错误，而是离线学习共同面对的数据覆盖问题。

第五部分

三种算法的统一理解与对比

PPO、GRPO 与 DPO 到底在优化什么

15.1 三个最终目标并列

PPO 的核心裁剪策略目标：

$$J_{\text{PPO}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (15.1)$$

其中

$$\rho_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}, \quad (15.2)$$

优势通常由价值模型与 GAE 计算。

GRPO 的核心目标：

$$J_{\text{GRPO}}(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_i \frac{1}{|o_i|} \sum_t \left(\min(\rho_{i,t} \hat{A}_{i,t}, \text{clip}(\rho_{i,t}, 1 - \epsilon, 1 + \epsilon) \hat{A}_{i,t}) - \beta \hat{D}_{i,t}^{\text{KL}} \right) \right], \quad (15.3)$$

其中 $\hat{A}_{i,t}$ 来自同题多个回答的组内相对奖励。

DPO 的核心损失：

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E}_{\mathcal{D}} \left[\log \sigma \left(\beta \left[\log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right] \right) \right]. \quad (15.4)$$

15.2 三者最核心的共同点

三种方法都在改变策略的对数概率：

$$\nabla_\theta \log \pi_\theta(\text{输出} | \text{条件}). \quad (15.5)$$

区别在于“这个输出应该被提高还是降低，以及提高多少”的信号来源：

- PPO：由环境奖励和价值基线产生 token 级优势。
- GRPO：由同一问题多个回答的相对奖励产生优势。

- DPO：由 winner/loser 偏好分类误差产生动态权重。

都可以粗略理解为

$$\text{梯度} \approx \text{行为方向} \times \text{质量或偏好权重} \times \text{稳定化机制}. \quad (15.6)$$

15.3 online 与 offline 的差别

表 15.1: 数据产生方式的差别

方面	PPO	GRPO	DPO
训练数据	当前/旧策略在线 rollout	当前/旧策略对每题在线采样一组回答	固定离线偏好对
训练中是否生成反馈形式	是 标量奖励、过程奖励或环境回报	是，而且每题生成多个组内可比较标量奖励	否 二元偏好标签
分布适应	新策略不断产生新数据	新策略不断产生新候选组	依赖固定数据覆盖

在线方法更昂贵，但反馈会随当前策略分布更新；离线 DPO 更简单稳定，但可能受数据分布偏移限制。

15.4 旧策略与参考策略的统一辨析

表 15.2: π_{old} 与 π_{ref} 的角色

概念	旧策略 π_{old}	参考策略 π_{ref}
主要作用	说明训练样本由哪个策略生成, 用于重要性概率比	规定长期行为锚点, 用于 KL 或 log-ratio 正则
更新频率	每轮 rollout 前后更新或快照	常固定为 SFT 模型, 也可按算法阶段更新
出现算法	PPO、GRPO	LLM PPO、GRPO、DPO
典型比值	$\pi_{\theta}/\pi_{\text{old}}$	$\pi_{\theta}/\pi_{\text{ref}}$
解决问题	同一批数据多轮更新时的分布校正	防止策略远离基础模型或过度优化奖励

15.5 绝对奖励、相对奖励与偏好标签

15.5.1 PPO：绝对期望回报下的相对优势

PPO 可以接收绝对标量奖励，但真正乘在策略梯度上的通常是

$$\hat{A}_t \approx Q(s_t, a_t) - V(s_t). \quad (15.7)$$

因此即使原始奖励是绝对分数，更新信号仍是动作相对状态基线的好坏。

15.5.2 GRPO：问题组内相对优势

GRPO 不学习跨所有状态的价值基线，而是计算

$$\hat{A}_i = \frac{r_i - \bar{r}_q}{s_{r,q}}. \quad (15.8)$$

这里基线只由同一个问题当前采到的候选构成。它更局部，也更依赖组采样质量。

15.5.3 DPO：成对回答的相对隐式奖励

DPO 学习

$$\hat{r}_\theta(x, y_w) - \hat{r}_\theta(x, y_l), \quad (15.9)$$

而且

$$\hat{r}_\theta(x, y) = \beta \log \frac{\pi_\theta(y | x)}{\pi_{\text{ref}}(y | x)}. \quad (15.10)$$

它没有直接获得绝对奖励，也不需要识别只依赖 x 的奖励常数。

15.6 稳定化机制的差别

表 15.3: 三种算法如何防止过度更新

算法	稳定化方式
PPO	新旧策略概率比裁剪；可选 target KL early stop；LLM 中常附加参考策略 KL
GRPO	继承 PPO 裁剪；显式参考策略 KL；组内标准化奖励
DPO	参考策略 log-ratio 参数化；sigmoid 交叉熵使已正确样本梯度饱和；固定离线数据

PPO/GRPO 的裁剪限制的是单批数据上的更新激励；DPO 的参考模型比值来自其闭式最优策略参数化。虽然都出现概率比，但理论角色不同。

从梯度形式看三者的统一结构

16.1 PPO 的局部梯度

忽略裁剪平坦区、价值项与 KL 项，PPO 单样本目标为

$$\ell_t = \rho_t(\theta) \hat{A}_t. \quad (16.1)$$

梯度为

$$\nabla_{\theta} \ell_t = \hat{A}_t \nabla_{\theta} \rho_t(\theta) \quad (16.2)$$

$$= \rho_t(\theta) \hat{A}_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t). \quad (16.3)$$

在旧策略处 $\rho_t = 1$:

$$\nabla_{\theta} \ell_t = \hat{A}_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t). \quad (16.4)$$

正优势提高动作概率，负优势降低动作概率。

16.2 GRPO 的局部梯度

忽略裁剪平坦区与 KL，GRPO 的结构完全相同：

$$\nabla_{\theta} \ell_{i,t} = \rho_{i,t}(\theta) \hat{A}_{i,t} \nabla_{\theta} \log \pi_{\theta}(o_{i,t} | q, o_{i,<t}). \quad (16.5)$$

区别只在于 $\hat{A}_{i,t}$ 不是 GAE，而是组内相对奖励。

16.3 DPO 的局部梯度

DPO 单样本梯度为

$$\nabla_{\theta} \ell_{\text{DPO}} = -w_{\theta} [\nabla_{\theta} \log \pi_{\theta}(y_w | x) - \nabla_{\theta} \log \pi_{\theta}(y_l | x)], \quad (16.6)$$

其中

$$w_{\theta} = \beta \sigma(-z_{\theta}) > 0. \quad (16.7)$$

梯度下降会沿 $-\nabla \ell$ 更新，因此提高 winner 的 log probability，降低 loser 的 log probability；权重由当前偏好排序错误程度决定。

16.4 统一模板

三者都可写成某种“加权对数似然梯度”：

$$\Delta \theta \propto \sum_j w_j \nabla_{\theta} \log \pi_{\theta}(y_j | x_j). \quad (16.8)$$

- PPO/GRPO： w_j 是带概率比、裁剪与优势的权重，可正可负。
- DPO： winner 权重为正、loser 权重为负，二者绝对值相同并由 sigmoid 动态确定。

这有助于理解它们为什么都能用普通自动微分训练，但不能据此忽略它们在数据分布、目标假设和信用分配上的根本差异。

应该如何选择以及常见误区

17.1 选择建议

表 17.1: 按训练条件选择算法

条件	更合适的方向
有可交互环境、工具执行结果或在线可验证奖励,需要策略探索新轨迹	PPO 或其变体; 若价值模型可训练且需要较细信用分配, PPO 更自然
每个问题可高效采样多个回答,有可靠可验证奖励,希望省去价值模型	GRPO 或其他 group-relative / critic-free 方法
已有高质量离线 winner/loser 数据,在线 rollout 和奖励模型运行成本高	DPO
偏好数据覆盖不足,但可在线获得新评分	在线 PPO/GRPO, 或迭代生成偏好后再做 DPO
奖励只在末尾给出,长程信用分配极其关键	单纯 outcome GRPO 可能较粗糙; 考虑过程奖励、价值模型或其他信用分配方法

17.2 误区一: PPO 的 clip 是硬约束

错误理解:

$$1 - \epsilon \leq \rho_t \leq 1 + \epsilon.$$

实际并没有这个硬约束。正确说法是: 超过阈值且继续变化会改善样本替代目标时, 目标进入平坦区; 参数仍可能因其他样本而继续变化。

17.3 误区二：PPO 是从 TRPO 严格等价化简得到的

PPO 继承了“小步更新”和局部替代目标思想，但裁剪目标是实用设计。它在旧策略处与策略梯度一阶一致，并对未裁剪替代目标做悲观裁剪，但不等于精确求解 TRPO 约束问题。

17.4 误区三：GRPO 的组均值是标准无偏 baseline

标准基线无偏证明要求基线在给定状态后不依赖当前动作。GRPO 组均值包含当前回答自身奖励，因此不满足该条件。未标准化时可推导出 $1 - 1/G$ 的收缩因子；标准差归一化又引入额外随机依赖。

17.5 误区四：GRPO 完全不需要旧策略

GRPO 去掉的是价值模型，不是旧策略。它仍使用

$$\frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})} \quad (17.1)$$

构造 PPO 式裁剪比值。

17.6 误区五：DPO 只是 winner SFT

DPO 同时使用 winner 和 loser，并比较它们相对参考策略的 log-ratio。其梯度还有依赖当前排序错误程度的 sigmoid 权重，和只训练 winner 的 SFT 不同。

17.7 误区六：DPO 的 beta 越大，模型一定离参考越远

从原始 KL 正则化目标看， β 越大，偏离参考策略的惩罚越强，理论最优策略通常越接近参考。不能只看到 DPO logit 中乘了 β 就得出相反结论。

17.8 误区七：参考策略和旧策略可以随意互换

旧策略用于解释当前数据来自哪里，参考策略规定长期行为锚点。将二者混淆会导致概率比、KL 正则和训练缓存的含义全部错乱。

17.9 误区八：优势为正就表示原始奖励为正

优势是相对基线的量。一个绝对奖励为负的回答，若比同状态或同组平均水平更好，仍可能具有正优势；反之，奖励为正但低于平均也可能具有负优势。

完整符号表

表 A.1: 本文主要符号及含义

符号	含义
θ	策略模型参数。
ψ	价值模型参数。
ϕ	奖励模型参数。
$\mathcal{S}, \mathcal{A}$	状态空间与动作空间。
s_t, a_t	第 t 步的状态和动作。
$P(s' s, a)$	环境转移概率。
ρ_0	初始状态分布。
γ	折扣因子。
λ	GAE 的偏差-方差折中参数；在拉格朗日推导章节中也临时表示拉格朗日乘子，语境不同。
$\pi_\theta(a s)$	当前参数化随机策略。
$\pi_{\theta_{\text{old}}}$	生成当前 rollout 数据的旧策略。
π_{ref}	冻结或阶段性固定的参考策略。
τ	一条完整轨迹。
r_t	第 t 步即时奖励。
$R(\tau)$	整条轨迹的累计回报。
G_t	从第 t 步开始的 reward-to-go。
$J(\theta)$	需要最大化的期望回报或策略目标。
$V^\pi(s)$	状态价值函数。
$Q^\pi(s, a)$	动作价值函数。
$A^\pi(s, a)$	优势函数 $Q^\pi(s, a) - V^\pi(s)$ 。
$V_\psi(s)$	参数化价值网络。
δ_t	TD error: $r_t + \gamma V(s_{t+1}) - V(s_t)$ 。
$\hat{A}_t$	由有限样本估计的优势。
$d_\gamma^\pi(s)$	折扣状态访问分布。
$\mathbb{E}[\cdot]$	数学期望。
$\hat{\mathbb{E}}_t[\cdot]$	对有限训练批次时间步的经验平均。
∇_θ	对参数 θ 的梯度。

符号	含义
$D_{\text{KL}}(p\ q)$	KL 散度 $\sum p \log(p/q)$ 。
$\rho_t(\theta)$ 或 $r_t(\theta)$	PPO 中当前策略与旧策略对已采动作的概率比。为避免与奖励混淆，正文后半多用 ρ 。
ϵ	PPO/GRPO 概率比裁剪半径。
$\text{clip}(x, l, u)$	把 x 截断到区间 $[l, u]$ 。
c_V, c_H	价值损失与熵奖励的权重。
$\mathcal{H}(\pi)$	策略熵。
x	DPO/RLHF 中的提示词。
y	完整回答序列。
$y_t, y_{<t}$	第 t 个回答 token 与它之前的前缀。
q	GRPO 中的问题；作用相当于提示词 x 。
o_i	GRPO 中同一问题的第 i 个采样回答。
G	GRPO 的 group size。
r_i	GRPO 中第 i 个回答的奖励。
$\bar{r}, s_r$	组内奖励均值与标准差。
$\hat{A}_{i,t}$	GRPO 中第 i 个回答第 t 个 token 的优势。
β	参考策略 KL 正则强度；在 DPO 闭式解中也是奖励温度参数。
$\mathcal{D}$	DPO 偏好数据集。
y_w, y_l	winner/preferred 与 loser/dispreferred 回答。
$>$	偏好关系，例如 $y_w > y_l$ 。
$\sigma(z)$	sigmoid 函数 $1/(1 + e^{-z})$ 。
$r^*(x, y)$	假设存在的真实潜在奖励。
$\hat{r}_\theta(x, y)$	DPO 隐式奖励 $\beta \log(\pi_\theta/\pi_{\text{ref}})$ 。
$Z(x)$	KL 正则化最优策略的配分函数。
z_θ	DPO 的偏好分类 logit。

关键公式的最短推导链

B.1 从期望回报到 REINFORCE

$$J(\theta) = \sum_{\tau} p_{\theta}(\tau) R(\tau), \quad (\text{B.1})$$

$$\nabla J = \sum_{\tau} p_{\theta}(\tau) R(\tau) \nabla \log p_{\theta}(\tau), \quad (\text{B.2})$$

$$\nabla \log p_{\theta}(\tau) = \sum_t \nabla \log \pi_{\theta}(a_t | s_t), \quad (\text{B.3})$$

$$\therefore \nabla J = \mathbb{E} \left[\sum_t G_t \nabla \log \pi_{\theta}(a_t | s_t) \right]. \quad (\text{B.4})$$

B.2 从 REINFORCE 到优势策略梯度

$$\mathbb{E}[\nabla \log \pi b(s)] = 0, \quad (\text{B.5})$$

$$G_t - b(s_t) \approx Q^{\pi}(s_t, a_t) - V^{\pi}(s_t), \quad (\text{B.6})$$

$$\therefore \nabla J = \mathbb{E}[\nabla \log \pi A^{\pi}]. \quad (\text{B.7})$$

B.3 从旧策略数据到 PPO

$$\rho_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\text{old}}(a_t | s_t)}, \quad (\text{B.8})$$

$$L^{\text{CPI}} = \hat{\mathbb{E}}_t[\rho_t \hat{A}_t], \quad (\text{B.9})$$

$$L^{\text{CLIP}} = \hat{\mathbb{E}}_t \left[\min(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t) \right]. \quad (\text{B.10})$$

B.4 从 PPO 到 GRPO

$$o_i \sim \pi_{\text{old}}(\cdot | q), \quad i = 1, \dots, G, \quad (\text{B.11})$$

$$\hat{A}_i = \frac{r_i - \text{mean}(r)}{\text{std}(r) + \epsilon_{\text{num}}}, \quad (\text{B.12})$$

$$\hat{A}_{i,t} = \hat{A}_i \quad (\text{outcome supervision}), \quad (\text{B.13})$$

$$J_{\text{GRPO}} = \mathbb{E} \left[\text{PPO-Clip}(\rho_{i,t}, \hat{A}_{i,t}) - \beta \hat{D}_{i,t}^{\text{KL}} \right]. \quad (\text{B.14})$$

B.5 从 KL 正则化 RLHF 到 DPO

$$\max_{\pi} \quad \mathbb{E}_{y \sim \pi} [r(x, y)] - \beta D_{\text{KL}}(\pi \| \pi_{\text{ref}}), \quad (\text{B.15})$$

$$\pi_r^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) e^{r(x,y)/\beta}, \quad (\text{B.16})$$

$$r(x, y) = \beta \log \frac{\pi_r^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x), \quad (\text{B.17})$$

$$\mathbb{P}(y_w > y_l | x) = \sigma(r(x, y_w) - r(x, y_l)), \quad (\text{B.18})$$

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} \log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right). \quad (\text{B.19})$$

自测题与答案

题目 1：为什么基线不能依赖当前动作？

假设把基线写成 $b(s, a)$ 。说明为什么一般不能保证

$$\mathbb{E}_{a \sim \pi}[\nabla \log \pi(a | s) b(s, a)] = 0.$$

答案

因为

$$\mathbb{E}[\nabla \log \pi(a | s) b(s, a)] = \sum_a \nabla \pi(a | s) b(s, a), \quad (\text{C.1})$$

无法把 $b(s, a)$ 提出求和，也不再等于 $b(s) \nabla \sum_a \pi(a | s)$ 。动作相关基线会对不同动作施加不同系统性权重，从而通常引入偏差。

题目 2：PPO 中 $\hat{A} > 0$ 且 $\rho < 1 - \epsilon$ 时为什么不裁剪？

答案

此时好动作的概率被错误降低。未裁剪项 $\rho \hat{A}$ 小于裁剪项 $(1 - \epsilon) \hat{A}$ ，min 选择未裁剪项，因此仍保留推动概率回升的梯度。PPO 只裁掉“越界且继续改善目标”的激励。

题目 3：GRPO 的某个回答奖励为零，它的优势一定为零吗？

答案

不一定。优势为

$$\hat{A}_i = (r_i - \bar{r}) / s_r.$$

若组均值为正，则零奖励回答是负优势；若组均值为负，则它可能是正优势。

题目 4：为什么 DPO 中 $Z(x)$ 可以消失？

答案

反解奖励时出现 $\beta \log Z(x)$ ，但 Bradley–Terry 概率只使用同一提示词下两个回答的奖励差。两个奖励都包含相同的 $\beta \log Z(x)$ ，相减后完全抵消。

题目 5：DPO 是否需要计算词表上的配分函数 $Z(x)$ ？

答案

不需要。DPO 通过奖励差消掉 $Z(x)$ ，只计算策略与参考策略对给定 winner/loser 序列的 log probability。

题目 6：为什么 PPO 与 GRPO 仍是 on-policy 风格？

答案

它们的数据由最近的旧策略生成，并只在有限轮更新中复用。策略更新后需要重新 rollout。概率比与裁剪允许有限的偏离，但不是把任意陈旧数据变成完全可靠的 off-policy 数据。

结语

PPO、GRPO 和 DPO 看似是三套不同公式，实际可以沿两条主线理解：

1. **策略梯度主线：**期望回报 $\rightarrow$ 对数导数技巧 $\rightarrow$ REINFORCE $\rightarrow$ 基线与优势 $\rightarrow$ 重要性比与信赖域 $\rightarrow$ PPO；GRPO 在此基础上用组内相对奖励替换 critic 优势估计。
2. **偏好建模主线：**Bradley-Terry 比较概率 + KL 正则化 RLHF 目标 $\rightarrow$ 闭式最优策略 $\rightarrow$ 奖励的策略 log-ratio 参数化 $\rightarrow$ DPO 二分类损失。

最重要的不是记住最终公式，而是区分每一步属于哪一类：

- 对数导数、重要性采样、拉格朗日闭式解属于数学恒等或严格优化推导；
- 用旧状态分布替代新状态分布、同批数据多轮更新属于局部近似；
- PPO 裁剪、GRPO 组内标准化属于为稳定训练设计的实用目标；
- DPO 的等价性依赖 KL 正则化目标与偏好概率模型等假设。

理解这些边界后，面对 Dr. GRPO、DAPO、GSPO、RLOO、IPO、KTO 等后续方法时，就能判断它们究竟改动了采样、优势估计、重要性比、正则化方式，还是偏好概率模型。

参考文献

- [1] R. J. Williams. Simple Statistical Gradient-Following Algorithms for Connectionist Reinforcement Learning. *Machine Learning*, 1992.
- [2] R. S. Sutton, D. McAllester, S. Singh, and Y. Mansour. Policy Gradient Methods for Reinforcement Learning with Function Approximation. *NeurIPS*, 2000.
- [3] J. Schulman, S. Levine, P. Moritz, M. I. Jordan, and P. Abbeel. Trust Region Policy Optimization. *ICML*, 2015.
- [4] J. Schulman, P. Moritz, S. Levine, M. Jordan, and P. Abbeel. High-Dimensional Continuous Control Using Generalized Advantage Estimation. arXiv:1506.02438, 2015.
- [5] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017.
- [6] L. Ouyang et al. Training Language Models to Follow Instructions with Human Feedback. *NeurIPS*, 2022.
- [7] R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, and C. Finn. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *NeurIPS*, 2023. arXiv:2305.18290.
- [8] Z. Shao et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. arXiv:2402.03300, 2024.